

Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias de la Computación



T E S I S

**“Predicción de congestión en redes de computadoras
utilizando técnicas de Machine Learning”**

Presenta:

Ricardo Valera Martínez

Para obtener el grado de:

Licenciatura en Ingeniería en Ciencias de la Computación

Director: **Mauro Alberto López Muñoz**

Codirector: **Guillermo Colorado Jiménez**

Puebla, Pue., Febrero 2026

Índice general

1. Introducción	6
1.1. Planteamiento del problema	6
1.2. Objetivos	7
1.2.1. Objetivo General	7
1.2.2. Objetivos Específicos	7
1.3. Justificación	8
1.4. Alcances y Limitaciones	9
2. Marco Teórico	11
2.1. Fundamentos de redes de computadoras	11
2.1.1. Modelo OSI y TCP/IP	13
2.1.2. Concepto de congestión	14
2.1.3. Métricas de rendimiento	15
2.2. Técnicas de Machine Learning aplicables	15
2.2.1. Aprendizaje supervisado: regresión vs clasificación	15
2.2.2. Modelos de series temporales (ARIMA)	15
2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)	15
2.2.4. Modelos de Deep Learning (LSTM, GRU)	15
2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)	15
3. Estado del Arte	16
3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos . .	16
3.2. Predicción de tráfico/congestión con Machine Learning clásico	16
3.3. Predicción con Deep Learning	16
3.4. Herramientas de monitoreo y datasets utilizados	16
3.5. Síntesis del estado del arte y brecha a cubrir	16
4. Metodología	17
4.1. Tipo de investigación	17
4.2. Definición operativa de congestión	17
4.3. Descripción de las métricas a utilizar	17
4.4. Fuente de datos	17
4.5. Preprocesamiento de datos	17
4.6. Modelos a implementar y justificación de su elección	17
4.7. Métricas de evaluación del modelo	17

4.8. Herramientas y entorno	17
5. Desarrollo e Implementación	18
5.1. Obtención y exploración del dataset	18
5.2. Preprocesamiento	18
5.3. Construcción del modelo ARIMA	18
5.4. Construcción del modelo Random Forest	18
5.5. Construcción del modelo LSTM	18
6. Resultados y Discusión	19
6.1. Resultados de ARIMA	19
6.2. Resultados de Random Forest	19
6.3. Resultados de LSTM	19
6.4. Comparativa de modelos	19
6.5. Discusión	19
7. Conclusiones	20
7.1. Cumplimiento de objetivos	20
7.2. Contribuciones	20
7.3. Limitaciones del estudio	20
Referencias bibliográficas	21
A. Código fuente de ejemplos críticos	23
B. Capturas de pantalla adicionales	24

Índice de figuras

2.1. Representación de una red entre dos computadoras.	11
2.2. Capas del modelo OSI.	14

Índice de cuadros

DEDICATORIA

*A mi padre, **Ricardo Valera Hernández**, por ser el pilar constante en cada etapa de mi formación, por su paciencia, su apoyo incondicional y por nunca dejar de creer en mí incluso cuando yo dudaba, por su ejemplo de responsabilidad y esfuerzo, por enseñarme que el trabajo honesto y la perseverancia son el camino para alcanzar cualquier meta.*

*A mi madre, **María Margarita Irma Martínez Pérez**, por ser la guía y el apoyo incondicional que hizo posible este trayecto. Gracias por su confianza infinita, por sus palabras que siempre supieron darme fuerza y por estar presente en cada paso de mi formación profesional. Este trabajo es testimonio de su esfuerzo y dedicación constante en mi vida.*

*A mi novia, **Vanessa F. Linarte Castañeda**, por su amor, su comprensión y su compañía en los momentos de cansancio y dificultad, por motivarme a seguir adelante cuando parecía imposible y por ser parte fundamental de este logro.*

*A mi hermano menor, **Emilio Valera Martínez**, por su complicidad y apoyo en los momentos de distracción y de enfoque. Gracias por estar ahí, por los consejos y por ser un compañero constante en este camino.*

*Al **Sr. Héctor H. Linarte** y la **Sra. Cristina E. Castañeda**, por recibirme en su familia como a un hijo más, por sus palabras de aliento y por el apoyo incondicional brindado durante este proceso. Su confianza y cariño fueron fundamentales para mantener el ánimo en la recta final.*

*A mi director de tesis, el **Mtro. Mauro Alberto López Muñoz**, y a mi codirector, el **Mtro. Guillermo Colorado Jiménez**, por su invaluable guía, su paciencia y por compartir su conocimiento para llevar este proyecto a buen puerto.*

Capítulo 1

Introducción

“El futuro de las redes de computadoras no solo depende de transmitir datos más rápido, sino de hacerlo de manera inteligente.”

La evolución en las redes de computadoras ha permitido el desarrollo de una gran cantidad de servicios y aplicaciones que forman parte de la vida cotidiana, desde la navegación web y las plataformas de comunicación, hasta los sistemas distribuidos, la computación en la nube y el intercambio masivo de información en tiempo real. Debido a este crecimiento constante en la cantidad de dispositivos conectados y el volumen de tráfico generado, las redes modernas enfrentan cada vez mayores desafíos relacionados con el rendimiento, la disponibilidad y la calidad del servicio.

1.1. Planteamiento del problema

Vivimos en una era digital en la que la conectividad se ha convertido en un servicio esencial, tan fundamental como la electricidad o el agua corriente. Desde las videollamadas que nos acercan a nuestros familiares y colegas, hasta las plataformas de streaming que nos ofrecen entretenimiento bajo demanda, pasando por la explosión del internet de las cosas (IoT) que llena nuestros hogares y ciudades de sensores inteligentes, gran parte de nuestra vida cotidiana depende de un flujo constante e ininterrumpido de datos. Según el informe *Cisco Annual Internet Report (2018–2023)*, el número de usuarios de Internet a nivel mundial pasó de 3900 millones en 2018 a 5300 millones en 2023, mientras que los dispositivos conectados a redes IP aumentaron de 18 400 millones a 29 300 millones en el mismo período [1].

Las redes de computadoras son el tejido que sostiene cambios inminentes en la industria. Sin embargo, no son un recurso infinito: cada enrutador, cada conmutador y cada enlace de fibra óptica tiene una capacidad limitada. Cuando la demanda de transmisión de datos supera esa capacidad se produce un fenómeno conocido como congestión de red. En términos sencillos (más adelante se abordará una definición apropiada para este trabajo), la congestión es el equivalente digital a un embotellamiento en una autopista: demasiados coches (paquetes de datos) intentando circular al mismo tiempo por un carril con aforo máximo. Las consecuencias se vuelven inmediatas y totalmente perceptibles para el usuario final: videollamadas

que se congelan, páginas web que cargan con lentitud, archivos que no terminan de descargarse o, en el peor de los casos, se pierde totalmente la conexión. En entornos críticos como hospitales, sistemas de redes financieras o redes industriales, estos fallos se traducen en pérdidas económicas millonarias o incluso riesgos para la seguridad de las personas.

Tradicionalmente, la gestión de redes ha tenido un enfoque reactivo: los administradores monitorizan equipos y, cuando detectan que un enlace está saturado, toman medidas correctivas como redirigir el tráfico, limitar ciertas aplicaciones o aumentar la capacidad del enlace. Este modo de actuar, aunque ha resultado funcional durante décadas, presenta una limitación fundamental: actúa después de que el problema ya ha comenzado a degradar la calidad del servicio. Pensemos en un coche autónomo que necesita tomar decisiones en milisegundos en tiempo real o en un cirujano operando a distancia mediante un robot; reaccionar después ya no es una opción, se necesita anticipación.

En este contexto, surge una pregunta clave: ¿es posible predecir que un enlace se va a congestionar con suficiente antelación para que un sistema automático o un administrador pueda evitarlo? La respuesta a esta pregunta pasa por abandonar la simple monitorización para adentrarse en el terreno del análisis predictivo. Aquí es donde entran en juego las técnicas de Machine Learning (ML), una rama de la inteligencia artificial que permite a las máquinas aprender patrones a partir de datos históricos y realizar predicciones sin ser programadas explícitamente para cada escenario.

El presente trabajo de tesis se sitúa justo en esta intersección entre las redes de computadoras y la inteligencia artificial. El objetivo central es desarrollar un sistema basado en técnicas de Machine Learning que sea capaz de predecir la congestión en un enlace de red a partir del análisis de métricas de tráfico obtenidas de forma pasiva. En lugar de limitarnos a reaccionar cuando la utilización ya está en niveles críticos, busco construir un modelo que pueda alertar con varios minutos de antelación: “Atención: este enlace alcanzará el 85 % de su capacidad; toma medidas ahora”.

1.2. Objetivos

A continuación se detallan los objetivos que guían el presente trabajo de tesis, los cuales fueron definidos en el protocolo de investigación y constituyen la hoja de ruta para el desarrollo del sistema propuesto.

1.2.1. Objetivo General

El objetivo general es desarrollar un sistema basado en Machine Learning que permita predecir la congestión de redes de computadoras a partir del análisis de datos de operación, con el fin de optimizar la gestión de recursos, mejorar el rendimiento y garantizar la calidad del servicio en diferentes entornos.

1.2.2. Objetivos Específicos

- Recopilar y organizar datos de operación de una red de computadoras, incluyendo parámetros como frecuencia de operación, ancho de banda, rendimiento y disponibili-

dad.

- Diseñar un procedimiento para almacenar, depurar y procesar los datos obtenidos de una manera estructurada.
- Implementar técnicas de Machine Learning adecuadas para analizar los patrones de tráfico y comportamiento de la red.
- Desarrollar un prototipo que realice predicciones de posibles escenarios de congestión de red.
- Validar el desempeño del sistema mediante métricas de evaluación.
- Identificar posibles aplicaciones reales del sistema propuesto en distintos contextos de uso.

1.3. Justificación

El crecimiento exponencial del tráfico en las redes de computadoras ha superado las estrategias tradicionales de gestión basadas en la monitorización reactiva. Hoy en día, la demanda de ancho de banda generada por servicios de videoconferencia, plataformas de streaming, aplicaciones en la nube y dispositivos del Internet de las Cosas somete a las infraestructuras a picos de utilización impredecibles. En este escenario, los administradores se ven forzados a intervenir únicamente después de que los niveles de congestión ya han degradado la calidad del servicio, lo que deriva en una experiencia deficiente para los usuarios y, en ámbitos críticos, en pérdidas económicas o riesgos de seguridad. Por ello, se vuelve indispensable desarrollar herramientas que permitan anticipar la saturación de los enlaces, migrando de una operación reactiva a una gestión predictiva que tome decisiones antes de que la congestión se materialice.

La aplicación de técnicas de Machine Learning en el ámbito de las redes abre una oportunidad real para este cambio de paradigma [2]. A diferencia de los métodos estadísticos convencionales, los algoritmos de aprendizaje automático tienen la capacidad de descubrir patrones complejos y no lineales a partir de grandes volúmenes de datos de operación, como series temporales de utilización, latencia o pérdida de paquetes. Modelos como las redes neuronales recurrentes, los bosques aleatorios o las arquitecturas de aprendizaje profundo han demostrado un desempeño notable en la predicción de tráfico en otros contextos, pero su aplicación sistemática para anticipar la congestión en enlaces individuales constituye un área de investigación con vacíos aún por cubrir, particularmente en lo referente a la comparación de múltiples familias de modelos en condiciones realistas de operación.

En el ámbito práctico, un sistema que prediga con antelación suficiente que un enlace alcanzará su capacidad límite puede transformar la administración de redes. Por ejemplo, un operador podría redirigir flujos de tráfico, activar mecanismos de balance de carga, reducir la prioridad de aplicaciones no críticas o incluso aprovisionar recursos adicionales de forma automática antes de que el usuario note degradación alguna. Esta capacidad de anticipación resulta crucial en entornos donde la continuidad del servicio es prioritaria, como hospitales que dependen de telemedicina, entidades financieras con transacciones en tiempo real o plantas

industriales con procesos automatizados. De esta manera, la presente investigación no solo busca generar conocimiento teórico, sino también ofrecer una herramienta con un impacto directo en la fiabilidad y eficiencia de las infraestructuras digitales.

Desde el punto de vista metodológico, la propuesta de construir un prototipo basado en datos de operación reales y de evaluarlo mediante métricas rigurosas —como el error cuadrático medio, el error absoluto medio y la comparación de tasas de predicción a distintos horizontes temporales— aporta un procedimiento replicable para la comunidad académica y profesional. La selección de tres paradigmas de modelado (series temporales estadísticas, aprendizaje automático clásico y aprendizaje profundo) permite además trazar un mapa claro de las fortalezas y limitaciones de cada enfoque, ofreciendo criterios objetivos para futuras implementaciones. En un campo en el que la mayoría de los estudios se concentran en la predicción general del volumen de tráfico, esta tesis se distingue por colocar el foco en la detección temprana de un evento específico y operacionalmente relevante: la congestión.

Finalmente, la investigación se justifica por su alineación con las tendencias actuales de la industria hacia las redes autónomas y la inteligencia artificial aplicada a las operaciones de TI (AIOps). Grandes empresas del sector tecnológico y organismos de estandarización están impulsando la incorporación de modelos predictivos en los sistemas de gestión de red, reconociendo que la simple supervisión ya no es suficiente para soportar las demandas de latencia y disponibilidad de las aplicaciones del futuro. En este sentido, el trabajo propuesto contribuye a cerrar la brecha entre las capacidades teóricas del Machine Learning y su aplicación práctica en un problema real de ingeniería de redes, generando evidencia empírica sobre su viabilidad, precisión y pertinencia en escenarios de congestión.

1.4. Alcances y Limitaciones

El presente trabajo de tesis se circunscribe al desarrollo de un prototipo funcional de predicción de congestión, implementado enteramente en código y orientado a validar la viabilidad sobre un conjunto de datos de operación de red. El alcance del proyecto se limita a la construcción, entrenamiento y evaluación de estos modelos mediante métricas cuantitativas, sin comprometerse con el desarrollo de una interfaz gráfica de usuario, una aplicación empaquetada o un sistema de producción completo. Por lo tanto, los resultados deben interpretarse como una prueba de concepto que demuestra la capacidad predictiva de los algoritmos seleccionados, no como una solución lista para ser desplegada en un entorno operacional real.

En términos de datos, el prototipo trabaja sobre un único dataset recolectado de forma pasiva en un escenario de red específico. Si bien esto permite controlar las condiciones del experimento y asegurar la reproducibilidad, también restringe la generalización de las conclusiones a otras topologías, escalas de red o patrones de tráfico. No se contempla, por el momento, la adquisición de múltiples fuentes de datos, la simulación de diversas arquitecturas de red ni la incorporación de tráfico sintético. Estas decisiones metodológicas, comunes en estudios de factibilidad tempranos, constituyen una limitación que deberá ser abordada en futuras iteraciones del sistema [3].

Desde el punto de vista computacional, se ha establecido un límite práctico en la complejidad de los algoritmos y en los recursos de hardware empleados. El prototipo se ejecuta en un entorno de estación de trabajo convencional, sin recurrir a infraestructura de cómputo

distribuido o aceleración especializada (GPU de alto rendimiento). En consecuencia, los modelos profundos se configuran con un número acotado de capas y neuronas, y no se explora el ajuste exhaustivo de hiperparámetros mediante búsqueda en malla de gran tamaño. Este enfoque permite obtener resultados en tiempos razonables, pero sacrifica potencialmente la obtención del modelo óptimo absoluto, lo cual es una limitación deliberada acorde con el carácter prototípico del desarrollo.

Otra restricción relevante es que el sistema no opera en tiempo real sobre una red viva, sino que entrena y evalúa sobre trazas históricas. La predicción se realiza fuera de línea, asumiendo que los datos han sido previamente recolectados y preprocesados. Por tanto, no se han implementado mecanismos de ingestión continua de datos, detección de cambio de concepto ni reentrenamiento automático del modelo, aspectos que resultarían necesarios para una eventual transición a un sistema de alerta temprana en producción. Esta limitación es congruente con la elección de priorizar la comparación de modelos bajo condiciones controladas [4].

Finalmente, la evaluación de la congestión se efectúa exclusivamente sobre el factor de utilización del enlace. Otras métricas que pueden incidir en la percepción de congestión, como la variación del retardo (jitter) o la tasa de pérdida de paquetes, no son modeladas de manera directa por el prototipo, aunque se mencionan en la fundamentación teórica. Esta delimitación conceptual simplifica el problema de predicción y permite concentrar los esfuerzos en la metodología propuesta, pero reconoce que la congestión es un fenómeno multifactorial que podría beneficiarse de un análisis más holístico en el futuro.

Capítulo 2

Marco Teórico

2.1. Fundamentos de redes de computadoras

Imaginemos por un momento dos computadoras aisladas, cada una con información valiosa almacenada en su interior. Para que esos datos puedan ser aprovechados por el otro equipo, alguien debe copiarlos en un dispositivo de almacenamiento externo, trasladarlos físicamente e introducirlos en la segunda máquina. Este procedimiento, aunque funcional, es lento, propenso a errores humanos y completamente inviable cuando la cantidad de información crece o cuando quien la necesita se encuentra a cientos o miles de kilómetros de distancia. Precisamente para resolver esta limitación nacieron las redes de computadoras: sistemas que conectan dos o más dispositivos de cómputo mediante algún medio de transmisión —cables de cobre, fibra óptica o el espectro electromagnético— con el propósito de intercambiar datos de manera rápida, confiable y eficiente.

En esencia, una red de computadoras es un conjunto de nodos autónomos interconectados que cooperan para compartir recursos e información. El término “nodo” designa a cualquier dispositivo capaz de originar, recibir o retransmitir datos: computadoras personales, servidores, teléfonos móviles, sensores, impresoras e incluso electrodomésticos inteligentes. Estos nodos se comunican a través de enlaces, que son los caminos físicos o inalámbricos por los que viaja la información. A su vez, los enlaces se conectan entre sí por medio de dispositivos de interconexión como conmutadores y enrutadores, cuya misión es encaminar los datos desde su origen hasta su destino, eligiendo la ruta más adecuada en cada momento y gestionando las colas de espera que se forman cuando varios flujos de tráfico coinciden en un mismo punto.




Figura 2.1: Representación de una red entre dos computadoras.

El funcionamiento de una red se organiza de manera jerárquica para domar la complejidad inherente a la comunicación digital. Esta organización se plasma en los llamados modelos de referencia, que dividen el problema de transmitir información en varias capas superpuestas,

cada una con responsabilidades claramente acotadas. Las capas inferiores se ocupan de los aspectos físicos: voltajes, pulsos de luz, ondas de radio y el significado de los bits individuales. Las capas intermedias gestionan el direccionamiento y el enrutamiento, decidiendo por qué camino debe viajar cada paquete de datos. Las capas superiores se preocupan por la integridad de la información, la sincronización de las conversaciones y, finalmente, por la interacción con las aplicaciones que el usuario ve en pantalla. Esta arquitectura en capas permite que un fabricante mejore un componente sin necesidad de rediseñar toda la red, y que tecnologías muy dispares puedan interoperar siempre que respeten los protocolos definidos en cada nivel.

Ahora bien, ¿cómo viajan realmente los datos a través de esta estructura? La respuesta depende del paradigma de conmutación que emplee la red. En las redes telefónicas tradicionales se usaba la conmutación de circuitos: cuando dos personas iniciaban una llamada, la red reservaba un camino físico dedicado y exclusivo entre ellas durante toda la conversación. Este enfoque garantiza una calidad constante, pero es terriblemente ineficiente: si los interlocutores hacen una pausa de diez segundos, el circuito permanece ocioso y nadie más puede aprovecharlo. Las redes de computadoras modernas, incluida Internet, optaron por un modelo radicalmente distinto: la conmutación de paquetes. En este paradigma, los datos se fragmentan en pequeñas unidades llamadas paquetes o datagramas, y cada paquete viaja de nodo en nodo de manera independiente, compartiendo los enlaces con paquetes de otras comunicaciones. Cuando un remitente hace una pausa, otros aprovechan inmediatamente el enlace, lo que multiplica la eficiencia global. Esta compartición estadística de los recursos, sin embargo, tiene una contrapartida: si demasiados remitentes transmiten a la vez, los enlaces se saturan y aparece la congestión.

Cada enlace en una red posee una capacidad máxima de transmisión, denominada ancho de banda, que se mide en bits por segundo (bps). Un enlace de fibra óptica típico puede ofrecer 1 Gbps, mientras que una conexión inalámbrica doméstica quizás solo alcance 50 Mbps. El tráfico real que circula por el enlace en un momento dado se conoce como throughput o rendimiento efectivo, y su valor siempre es inferior o igual al ancho de banda nominal. La fracción entre el throughput y el ancho de banda se denomina factor de utilización y constituye una de las métricas más reveladoras sobre el estado de un enlace. Mientras la utilización se mantenga moderada —digamos, por debajo del 70 %—, la red opera con holgura. Conforme se aproxima al 100 %, comienzan a manifestarse los síntomas de la congestión.

Para entender por qué, hay que examinar qué ocurre dentro de un enrutador. Cada enrutador dispone de pequeñas memorias temporales llamadas buffers, donde almacena los paquetes que llegan mientras esperan ser procesados y reenviados por el enlace de salida correspondiente. Si los paquetes llegan a una tasa inferior a la capacidad del enlace de salida, el buffer apenas se llena y los paquetes son despachados casi de inmediato. Pero si, durante un cierto intervalo, la tasa de llegada supera la tasa de salida, la cola de espera dentro del buffer empieza a crecer. Este fenómeno es perfectamente análogo a lo que sucede en una caseta de cobro de una autopista: mientras los coches lleguen a un ritmo menor del que la caseta puede atender, la fila es corta y el retraso mínimo. Si llegan más coches de los que pueden ser atendidos, la fila se alarga y el tiempo de espera se dispara.

Ese tiempo de espera adicional que un paquete experimenta desde que ingresa a la red hasta que llega a su destino se conoce como latencia o retardo extremo a extremo. La latencia tiene varios componentes: el tiempo de propagación (lo que tarda la señal en viajar por el medio físico), el tiempo de transmisión (lo que tarda el emisor en poner todos los bits en el

medio), el tiempo de procesamiento en cada nodo y, crucialmente, el tiempo de encolado en los buffers. En condiciones normales, el tiempo de encolado es insignificante. Bajo congestión, en cambio, puede convertirse en el componente dominante de la latencia total. Además, como la llegada de paquetes es irregular e impredecible, el tamaño de la cola fluctúa, por lo que la latencia no solo aumenta, sino que se vuelve variable. Esa variabilidad se denomina jitter y resulta particularmente perjudicial para aplicaciones sensibles al tiempo, como las videollamadas o los juegos en línea.

Cuando la congestión se agrava, el buffer puede llenarse por completo. Llegado ese punto, el enrutador no tiene más opción que descartar los paquetes que no puede almacenar. Esa tasa de pérdida de paquetes es otro indicador clave de la salud de la red. Una pérdida de paquetes ocasional puede ser tolerable, pero cuando se vuelve frecuente, los protocolos de transporte —especialmente TCP— interpretan esas pérdidas como una señal de congestión y reducen drásticamente la velocidad de envío para aliviar la red. Aunque este mecanismo de control de congestión ha sido fundamental para la estabilidad de Internet, opera de manera reactiva: solo se activa después de que la congestión ya ha producido pérdidas. Para entonces, la calidad del servicio ya se ha degradado y los usuarios han notado el problema.

Además de la utilización, la latencia y la pérdida de paquetes, existe otro concepto fundamental para esta tesis: el cuello de botella. En cualquier ruta entre dos nodos, el enlace con menor capacidad determina la velocidad máxima a la que pueden fluir los datos, del mismo modo que el tramo más estrecho de una tubería limita el caudal total de agua. Los cuellos de botella son los puntos donde la congestión se manifiesta primero y con mayor intensidad, y por tanto son los candidatos naturales para aplicar técnicas de predicción y prevención.

Todas estas ideas —conmutación de paquetes, buffers, utilización, latencia, jitter, pérdida de paquetes y cuellos de botella— constituyen el vocabulario básico sobre el que se edifican los capítulos siguientes. Conocerlas permitirá al lector comprender con precisión qué significa exactamente la congestión de red (que se definirá formalmente en la siguiente sección), cómo se mide y, sobre todo, por qué vale la pena intentar predecirla antes de que sus efectos se vuelvan irreversibles. En la presente tesis, la congestión se abordará desde una perspectiva predictiva que se apoya en el análisis de series temporales de utilización de enlace, empleando modelos de aprendizaje automático capaces de detectar patrones precursores de saturación mucho antes de que los buffers se llenen y los paquetes comiencen a perderse.

2.1.1. Modelo OSI y TCP/IP

El Modelo de Interconexión de Sistemas Abiertos (OSI, *Open Systems Interconnection*), estandarizado por la Organización Internacional de Normalización (ISO) en 1984, constituye un marco conceptual que divide el proceso de comunicación en redes en siete capas funcionales independientes. Cada nivel abstrae un conjunto específico de responsabilidades, desde la transmisión física de bits hasta la interacción con las aplicaciones del usuario. Esta estratificación facilita la interoperabilidad entre equipos de distintos fabricantes y permite analizar los fenómenos de red, como la congestión, dentro de una estructura bien definida. En particular, la gestión de la congestión incide directamente en las capas de transporte y red, donde se regulan el control de flujo, el enrutamiento y la asignación de recursos, aspectos que serán modelados en este trabajo a partir de métricas de utilización.



Figura 2.2: Capas del modelo OSI.

2.1.2. Concepto de congestión

La congestión de red ocurre cuando la cantidad de datos que intenta atravesar un nodo o enlace supera su capacidad de procesamiento y transmisión. Este fenómeno es común en redes de comunicación donde múltiples dispositivos compiten de manera simultánea por los mismos recursos de red, provocando una degradación progresiva en el rendimiento general del sistema.

Una forma sencilla de comprender este problema es imaginar el ancho de banda como una tubería por la que circula agua. Mientras el flujo se mantenga dentro de la capacidad de la tubería, los datos pueden transmitirse de manera eficiente. Sin embargo, cuando la cantidad de paquetes excede un límite crítico, los depósitos temporales de los routers, conocidos como *buffers*, comienzan a llenarse rápidamente. Como consecuencia, los paquetes deben permanecer más tiempo en espera antes de ser procesados y reenviados, lo que incrementa la latencia de la comunicación. Este retraso no crece de forma lineal, sino que puede aumentar de manera acelerada y desproporcionada conforme se incrementa el tráfico de red.

Desde una perspectiva operativa, uno de los principales síntomas de la congestión es la pérdida de paquetes. Cuando la memoria intermedia del router alcanza su capacidad máxima, el dispositivo se ve obligado a descartar los paquetes entrantes debido a la falta de espacio disponible. Esta situación provoca retransmisiones por parte de los protocolos de comunicación, especialmente en TCP, lo que incrementa aún más la carga de tráfico y agrava el estado de congestión de la red.

Además de la pérdida de paquetes, la congestión puede ocasionar otros efectos negativos, como aumento en el tiempo de respuesta, variaciones en el retardo, disminución del rendimiento efectivo y una experiencia deficiente para aplicaciones sensibles al tiempo, como videollamadas, transmisión multimedia o servicios en tiempo real.

En esta tesis, la congestión de red se evalúa mediante el factor de utilización, el cual representa qué tan cerca se encuentra un enlace de alcanzar su capacidad máxima de transmisión. Este parámetro permite analizar el comportamiento de la red bajo diferentes niveles de carga

y determinar el punto en el que el rendimiento comienza a degradarse significativamente, provocando inestabilidad en la comunicación y reducción en la calidad del servicio.

2.1.3. Métricas de rendimiento

2.2. Técnicas de Machine Learning aplicables

2.2.1. Aprendizaje supervisado: regresión vs clasificación

2.2.2. Modelos de series temporales (ARIMA)

2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)

2.2.4. Modelos de Deep Learning (LSTM, GRU)

2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)

Capítulo 3

Estado del Arte

- 3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos
- 3.2. Predicción de tráfico/congestión con Machine Learning clásico
- 3.3. Predicción con Deep Learning
- 3.4. Herramientas de monitoreo y datasets utilizados
- 3.5. Síntesis del estado del arte y brecha a cubrir

Capítulo 4

Metodología

- 4.1. Tipo de investigación
- 4.2. Definición operativa de congestión
- 4.3. Descripción de las métricas a utilizar
- 4.4. Fuente de datos
- 4.5. Preprocesamiento de datos
- 4.6. Modelos a implementar y justificación de su elección
- 4.7. Métricas de evaluación del modelo
- 4.8. Herramientas y entorno

Capítulo 5

Desarrollo e Implementación

- 5.1. Obtención y exploración del dataset
- 5.2. Preprocesamiento
- 5.3. Construcción del modelo ARIMA
- 5.4. Construcción del modelo Random Forest
- 5.5. Construcción del modelo LSTM

Capítulo 6

Resultados y Discusión

- 6.1. Resultados de ARIMA
- 6.2. Resultados de Random Forest
- 6.3. Resultados de LSTM
- 6.4. Comparativa de modelos
- 6.5. Discusión

Capítulo 7

Conclusiones

7.1. Cumplimiento de objetivos

7.2. Contribuciones

7.3. Limitaciones del estudio

Referencias bibliográficas

Bibliografía

- [1] Cisco Systems, “Cisco annual internet report (2018–2023) white paper,” Cisco, Tech. Rep., 2020, consultado el 25 de mayo de 2026. [Online]. Available: <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>
- [2] R. Boutaba, M. A. Salahuddin, N. Limam, S. Ayoubi, N. Shahriar, F. Estrada-Solano, and O. M. Caicedo, “A comprehensive survey on machine learning for networking: evolution, applications and research opportunities,” *Journal of Internet Services and Applications*, vol. 9, no. 1, p. 16, 2018.
- [3] A. Boukerche, Y. Sun, and M. Z. A. Bhuiyan, “Performance evaluation of machine learning-based network traffic prediction approaches: A survey,” *IEEE Communications Surveys & Tutorials*, vol. 23, no. 1, pp. 405–428, 2021.
- [4] J. Zhang, Y. Liu, Z. Li, and Y. Lu, “Network traffic prediction using deep learning: An experimental study,” in *2020 IEEE 6th International Conference on Computer and Communications (ICCC)*, 2020, pp. 1320–1325.

Apéndice A

Código fuente de ejemplos críticos

Apéndice B

Capturas de pantalla adicionales