

Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias de la Computación



T E S I S

**“Predicción de congestión en redes de computadoras
utilizando técnicas de Machine Learning”**

Presenta:

Ricardo Valera Martínez

Para obtener el grado de:

Licenciatura en Ingeniería en Ciencias de la Computación

Director: **Mauro Alberto López Muñoz**

Codirector: **Guillermo Colorado Jiménez**

Puebla, Pue., Febrero 2026

Índice general

1. Introducción	6
1.1. Planteamiento del problema	6
1.2. Objetivos	7
1.2.1. Objetivo General	8
1.2.2. Objetivos Específicos	8
1.3. Justificación	8
1.4. Alcances y Limitaciones	9
2. Marco Teórico	11
2.1. Fundamentos de redes de computadoras	11
2.1.1. Modelo OSI y TCP/IP	13
2.1.2. Concepto de congestión	14
2.1.3. Métricas de rendimiento	16
2.2. Técnicas de Machine Learning aplicables	19
2.2.1. Aprendizaje supervisado: regresión vs clasificación	19
2.2.2. Modelos de series temporales (ARIMA)	20
2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)	21
2.2.4. Modelos de Deep Learning (LSTM, GRU)	22
2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)	23
3. Estado del Arte	25
3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos	25
3.2. Predicción de tráfico/congestión con Machine Learning clásico	25
3.3. Predicción con Deep Learning	25
3.4. Herramientas de monitoreo y datasets utilizados	25
3.5. Síntesis del estado del arte y brecha a cubrir	25
4. Metodología	26
4.1. Tipo de investigación	26
4.2. Definición operativa de congestión	26
4.3. Descripción de las métricas a utilizar	26
4.4. Fuente de datos	26
4.5. Preprocesamiento de datos	28
4.6. Modelos a implementar y justificación de su elección	28
4.7. Métricas de evaluación del modelo	28

4.8. Herramientas y entorno	28
5. Desarrollo e Implementación	29
5.1. Obtención y exploración del dataset	29
5.2. Preprocesamiento	29
5.3. Construcción del modelo ARIMA	29
5.4. Construcción del modelo Random Forest	29
5.5. Construcción del modelo LSTM	29
6. Resultados y Discusión	30
6.1. Resultados de ARIMA	30
6.2. Resultados de Random Forest	30
6.3. Resultados de LSTM	30
6.4. Comparativa de modelos	30
6.5. Discusión	30
7. Conclusiones	31
7.1. Cumplimiento de objetivos	31
7.2. Contribuciones	31
7.3. Limitaciones del estudio	31
Referencias bibliográficas	32
A. Código fuente de ejemplos críticos	35
B. Capturas de pantalla adicionales	36

Índice de figuras

2.1. Representación de una red entre dos computadoras.	11
2.2. Capas del modelo OSI.	13
2.3. Ubicación del problema de predicción de congestión dentro de los paradigmas de Machine Learning.	20

Índice de cuadros

2.1. Resumen de métricas de rendimiento de red utilizadas en esta tesis.	19
2.2. Resumen comparativo de los modelos de predicción considerados en esta tesis.	24

DEDICATORIA

*A mi padre, **Ricardo Valera Hernández**, por ser el pilar constante en cada etapa de mi formación, por su paciencia, su apoyo incondicional y por nunca dejar de creer en mí incluso cuando yo dudaba, por su ejemplo de responsabilidad y esfuerzo, por enseñarme que el trabajo honesto y la perseverancia son el camino para alcanzar cualquier meta.*

*A mi madre, **María Margarita Irma Martínez Pérez**, por ser la guía y el apoyo incondicional que hizo posible este trayecto. Gracias por su confianza infinita, por sus palabras que siempre supieron darme fuerza y por estar presente en cada paso de mi formación profesional. Este trabajo es testimonio de su esfuerzo y dedicación constante en mi vida.*

*A mi novia, **Vanessa F. Linarte Castañeda**, por su amor, su comprensión y su compañía en los momentos de cansancio y dificultad, por motivarme a seguir adelante cuando parecía imposible y por ser parte fundamental de este logro.*

*A mi hermano menor, **Emilio Valera Martínez**, por su complicidad y apoyo en los momentos de distracción y de enfoque. Gracias por estar ahí, por los consejos y por ser un compañero constante en este camino.*

*Al **Sr. Héctor H. Linarte** y la **Sra. Cristina E. Castañeda**, por recibirme en su familia como a un hijo más, por sus palabras de aliento y por el apoyo incondicional brindado durante este proceso. Su confianza y cariño fueron fundamentales para mantener el ánimo en la recta final.*

*A mi director de tesis, el **Mtro. Mauro Alberto López Muñoz**, y a mi codirector, el **Mtro. Guillermo Colorado Jiménez**, por su invaluable guía, su paciencia y por compartir su conocimiento para llevar este proyecto a buen puerto.*

Capítulo 1

Introducción

“El futuro de las redes de computadoras no solo depende de transmitir datos más rápido, sino de hacerlo de manera inteligente.”

La evolución en las redes de computadoras ha permitido el desarrollo de una gran cantidad de servicios y aplicaciones que forman parte de la vida cotidiana, desde la navegación web y las plataformas de comunicación, hasta los sistemas distribuidos, la computación en la nube y el intercambio masivo de información en tiempo real. Debido a este crecimiento constante en la cantidad de dispositivos conectados y el volumen de tráfico generado, las redes modernas enfrentan cada vez mayores desafíos relacionados con el rendimiento, la disponibilidad y la calidad del servicio.

1.1. Planteamiento del problema

Vivimos en una era digital en la que la conectividad se ha convertido en un servicio esencial, tan fundamental como la electricidad o el agua corriente. Desde las videollamadas que nos acercan a nuestros familiares y colegas, hasta las plataformas de streaming que nos ofrecen entretenimiento bajo demanda, pasando por la explosión del internet de las cosas (IoT) que llena nuestros hogares y ciudades de sensores inteligentes, gran parte de nuestra vida cotidiana depende de un flujo constante e ininterrumpido de datos. Según el informe *Cisco Annual Internet Report (2018–2023)*, el número de usuarios de Internet a nivel mundial pasó de 3900 millones en 2018 a 5300 millones en 2023, mientras que los dispositivos conectados a redes IP aumentaron de 18 400 millones a 29 300 millones en el mismo período [1].

Las redes de computadoras son el tejido que sostiene cambios inminentes en la industria. Sin embargo, no son un recurso infinito: cada enrutador, cada conmutador y cada enlace de fibra óptica tiene una capacidad limitada. Cuando la demanda de transmisión de datos supera esa capacidad se produce un fenómeno conocido como congestión de red. En términos sencillos (más adelante se abordará una definición apropiada para este trabajo), la congestión es el equivalente digital a un embotellamiento en una autopista: demasiados coches (paquetes de datos) intentando circular al mismo tiempo por un carril con aforo máximo. Las consecuencias se vuelven inmediatas y totalmente perceptibles para el usuario final: videollamadas

que se congelan, páginas web que cargan con lentitud, archivos que no terminan de descargarse o, en el peor de los casos, se pierde totalmente la conexión. En entornos críticos como hospitales, sistemas de redes financieras o redes industriales, estos fallos se traducen en pérdidas económicas millonarias o incluso riesgos para la seguridad de las personas.

Tradicionalmente, la gestión de redes ha tenido un enfoque reactivo: los administradores monitorizan equipos y, cuando detectan que un enlace está saturado, toman medidas correctivas como redirigir el tráfico, limitar ciertas aplicaciones o aumentar la capacidad del enlace. Este modo de actuar, aunque ha resultado funcional durante décadas, presenta una limitación fundamental: actúa después de que el problema ya ha comenzado a degradar la calidad del servicio. Pensemos en un coche autónomo que necesita tomar decisiones en milisegundos en tiempo real o en un cirujano operando a distancia mediante un robot; reaccionar después ya no es una opción, se necesita anticipación.

De lo anterior se desprende el problema central que da origen a esta investigación: los mecanismos actuales de gestión de redes de computadoras carecen, en su mayoría, de la capacidad de anticipar la congestión antes de que esta se manifieste, limitándose a detectarla y corregirla una vez que ya ha comenzado a degradar la calidad del servicio. Esta naturaleza reactiva impide a los administradores de red y a los sistemas automatizados de gestión tomar decisiones oportunas —como redirigir tráfico, priorizar aplicaciones críticas o escalar recursos— antes de que el impacto sea perceptible para el usuario final. El problema de investigación puede formularse, entonces, de la siguiente manera: **¿es posible, a partir del análisis de datos históricos de operación de una red, construir un modelo capaz de predecir con suficiente antelación que un enlace alcanzará un estado de congestión, de tal forma que dicha predicción resulte útil para la toma de decisiones antes de que la degradación del servicio se materialice?**

En este contexto, y una vez planteado formalmente el problema, las técnicas de Machine Learning (ML) se presentan como una vía prometedora para abordarlo. El ML, una rama de la inteligencia artificial, permite a las máquinas aprender patrones a partir de datos históricos y realizar predicciones sin ser programadas explícitamente para cada escenario, lo que lo convierte en una herramienta natural para atacar el problema de anticipación recién descrito.

El presente trabajo de tesis se sitúa justo en esta intersección entre las redes de computadoras y la inteligencia artificial. El objetivo central es desarrollar un sistema basado en técnicas de Machine Learning que sea capaz de predecir la congestión en un enlace de red a partir del análisis de métricas de tráfico obtenidas de forma pasiva. En lugar de limitarnos a reaccionar cuando la utilización ya está en niveles críticos, busco construir un modelo que pueda alertar con varios minutos de antelación: “Atención: este enlace alcanzará el 85 % de su capacidad; toma medidas ahora”.

1.2. Objetivos

A continuación se detallan los objetivos que guían el presente trabajo de tesis, los cuales fueron definidos en el protocolo de investigación y constituyen la hoja de ruta para el desarrollo del sistema propuesto.

1.2.1. Objetivo General

El objetivo general es desarrollar un sistema basado en Machine Learning que permita predecir la congestión de redes de computadoras a partir del análisis de datos de operación, evaluando su desempeño en escenarios de tráfico de distinta escala y naturaleza, con el fin de aportar evidencia sobre la viabilidad de este enfoque predictivo para optimizar la gestión de recursos y la calidad del servicio en redes de computadoras.

1.2.2. Objetivos Específicos

- Recopilar y organizar datos de operación de una red de computadoras, incluyendo parámetros como frecuencia de operación, ancho de banda, rendimiento y disponibilidad.
- Diseñar un procedimiento para almacenar, depurar y procesar los datos obtenidos de una manera estructurada.
- Implementar técnicas de Machine Learning adecuadas para analizar los patrones de tráfico y comportamiento de la red.
- Desarrollar un prototipo que realice predicciones de posibles escenarios de congestión de red.
- Validar el desempeño del sistema mediante métricas de evaluación.
- Identificar posibles aplicaciones reales del sistema propuesto en distintos contextos de uso.

1.3. Justificación

El crecimiento exponencial del tráfico en las redes de computadoras ha superado las estrategias tradicionales de gestión basadas en la monitorización reactiva. Hoy en día, la demanda de ancho de banda generada por servicios de videoconferencia, plataformas de streaming, aplicaciones en la nube y dispositivos del Internet de las Cosas somete a las infraestructuras a picos de utilización impredecibles. En este escenario, los administradores se ven forzados a intervenir únicamente después de que los niveles de congestión ya han degradado la calidad del servicio, lo que deriva en una experiencia deficiente para los usuarios y, en ámbitos críticos, en pérdidas económicas o riesgos de seguridad. Por ello, se vuelve indispensable desarrollar herramientas que permitan anticipar la saturación de los enlaces, migrando de una operación reactiva a una gestión predictiva que tome decisiones antes de que la congestión se materialice.

La aplicación de técnicas de Machine Learning en el ámbito de las redes abre una oportunidad real para este cambio de paradigma [2]. A diferencia de los métodos estadísticos convencionales, los algoritmos de aprendizaje automático tienen la capacidad de descubrir patrones complejos y no lineales a partir de grandes volúmenes de datos de operación, como series temporales de utilización, latencia o pérdida de paquetes. Modelos como las redes neuronales recurrentes, los bosques aleatorios o las arquitecturas de aprendizaje profundo han

demostrado un desempeño notable en la predicción de tráfico en otros contextos, pero su aplicación sistemática para anticipar la congestión en enlaces individuales constituye un área de investigación con vacíos aún por cubrir, particularmente en lo referente a la comparación de múltiples familias de modelos en condiciones realistas de operación.

En el ámbito práctico, un sistema que prediga con antelación suficiente que un enlace alcanzará su capacidad límite puede transformar la administración de redes. Por ejemplo, un operador podría redirigir flujos de tráfico, activar mecanismos de balance de carga, reducir la prioridad de aplicaciones no críticas o incluso aprovisionar recursos adicionales de forma automática antes de que el usuario note degradación alguna. Esta capacidad de anticipación resulta crucial en entornos donde la continuidad del servicio es prioritaria, como hospitales que dependen de telemedicina, entidades financieras con transacciones en tiempo real o plantas industriales con procesos automatizados. De esta manera, la presente investigación no solo busca generar conocimiento teórico, sino también ofrecer una herramienta con un impacto directo en la fiabilidad y eficiencia de las infraestructuras digitales.

Desde el punto de vista metodológico, la propuesta de construir un prototipo basado en datos de operación reales y de evaluarlo mediante métricas rigurosas —como el error cuadrático medio, el error absoluto medio y la comparación de tasas de predicción a distintos horizontes temporales— aporta un procedimiento replicable para la comunidad académica y profesional. La selección de tres paradigmas de modelado (series temporales estadísticas, aprendizaje automático clásico y aprendizaje profundo) permite además trazar un mapa claro de las fortalezas y limitaciones de cada enfoque, ofreciendo criterios objetivos para futuras implementaciones. En un campo en el que la mayoría de los estudios se concentran en la predicción general del volumen de tráfico, esta tesis se distingue por colocar el foco en la detección temprana de un evento específico y operacionalmente relevante: la congestión.

Finalmente, la investigación se justifica por su alineación con las tendencias actuales de la industria hacia las redes autónomas y la inteligencia artificial aplicada a las operaciones de TI (AIOps). Grandes empresas del sector tecnológico y organismos de estandarización están impulsando la incorporación de modelos predictivos en los sistemas de gestión de red, reconociendo que la simple supervisión ya no es suficiente para soportar las demandas de latencia y disponibilidad de las aplicaciones del futuro. En este sentido, el trabajo propuesto contribuye a cerrar la brecha entre las capacidades teóricas del Machine Learning y su aplicación práctica en un problema real de ingeniería de redes, generando evidencia empírica sobre su viabilidad, precisión y pertinencia en escenarios de congestión.

1.4. Alcances y Limitaciones

El presente trabajo de tesis se circunscribe al desarrollo de un prototipo funcional de predicción de congestión, implementado enteramente en código y orientado a validar la viabilidad sobre un conjunto de datos de operación de red. El alcance del proyecto se limita a la construcción, entrenamiento y evaluación de estos modelos mediante métricas cuantitativas, sin comprometerse con el desarrollo de una interfaz gráfica de usuario, una aplicación empaquetada o un sistema de producción completo. Por lo tanto, los resultados deben interpretarse como una prueba de concepto que demuestra la capacidad predictiva de los algoritmos seleccionados, no como una solución lista para ser desplegada en un entorno operacional real.

En términos de datos, el prototipo se desarrolla y evalúa sobre dos fuentes complementarias: una red privada de escala reducida sobre la cual se realizó recolección propia de datos de operación durante un periodo de dos meses, y un archivo académico de tráfico de Internet de gran escala empleado como conjunto de validación externa. Si bien esta combinación permite evaluar el desempeño de los modelos bajo condiciones de tráfico de naturaleza y escala distintas, ampliando el alcance de las conclusiones respecto de un estudio basado en una única fuente, no debe interpretarse como una validación exhaustiva sobre la totalidad de topologías, tecnologías de acceso o patrones de tráfico posibles en una red de computadoras. La generalización de los resultados a escenarios sustancialmente distintos a los aquí evaluados —por ejemplo, redes móviles, entornos industriales o infraestructuras de centros de datos— queda fuera del alcance de este trabajo y se plantea como una línea de investigación futura.

Desde el punto de vista computacional, se ha establecido un límite práctico en la complejidad de los algoritmos y en los recursos de hardware empleados. El prototipo se ejecuta en un entorno de estación de trabajo convencional, sin recurrir a infraestructura de cómputo distribuido o aceleración especializada (GPU de alto rendimiento). En consecuencia, los modelos profundos se configuran con un número acotado de capas y neuronas, y no se explora el ajuste exhaustivo de hiperparámetros mediante búsqueda en malla de gran tamaño. Este enfoque permite obtener resultados en tiempos razonables, pero sacrifica potencialmente la obtención del modelo óptimo absoluto, lo cual es una limitación deliberada acorde con el carácter prototípico del desarrollo.

Otra restricción relevante es que el sistema no opera en tiempo real sobre una red viva, sino que entrena y evalúa sobre trazas históricas. La predicción se realiza fuera de línea, asumiendo que los datos han sido previamente recolectados y preprocesados. Por tanto, no se han implementado mecanismos de ingestión continua de datos, detección de cambio de concepto ni reentrenamiento automático del modelo, aspectos que resultarían necesarios para una eventual transición a un sistema de alerta temprana en producción. Esta limitación es congruente con la elección de priorizar la comparación de modelos bajo condiciones controladas [3].

Finalmente, la evaluación de la congestión se efectúa exclusivamente sobre el factor de utilización del enlace. Otras métricas que pueden incidir en la percepción de congestión, como la variación del retardo (jitter) o la tasa de pérdida de paquetes, no son modeladas de manera directa por el prototipo, aunque se mencionan en la fundamentación teórica. Esta delimitación conceptual simplifica el problema de predicción y permite concentrar los esfuerzos en la metodología propuesta, pero reconoce que la congestión es un fenómeno multifactorial que podría beneficiarse de un análisis más holístico en el futuro.

Capítulo 2

Marco Teórico

2.1. Fundamentos de redes de computadoras

Imaginemos por un momento dos computadoras aisladas, cada una con información valiosa almacenada en su interior. Para que esos datos puedan ser aprovechados por el otro equipo, alguien debe copiarlos en un dispositivo de almacenamiento externo, trasladarlos físicamente e introducirlos en la segunda máquina. Este procedimiento, aunque funcional, es lento, propenso a errores humanos y completamente inviable cuando la cantidad de información crece o cuando quien la necesita se encuentra a cientos o miles de kilómetros de distancia. Precisamente para resolver esta limitación nacieron las redes de computadoras: sistemas que conectan dos o más dispositivos de cómputo mediante algún medio de transmisión —cables de cobre, fibra óptica o el espectro electromagnético— con el propósito de intercambiar datos de manera rápida, confiable y eficiente [4].

En esencia, una red de computadoras es un conjunto de nodos autónomos interconectados que cooperan para compartir recursos e información. El término "nodo" designa a cualquier dispositivo capaz de originar, recibir o retransmitir datos: computadoras personales, servidores, teléfonos móviles, sensores, impresoras e incluso electrodomésticos inteligentes. Estos nodos se comunican a través de enlaces, que son los caminos físicos o inalámbricos por los que viaja la información. A su vez, los enlaces se conectan entre sí por medio de dispositivos de interconexión como conmutadores y enrutadores, cuya misión es encaminar los datos desde su origen hasta su destino, eligiendo la ruta más adecuada en cada momento y gestionando las colas de espera que se forman cuando varios flujos de tráfico coinciden en un mismo punto. El comportamiento de estas colas de espera bajo condiciones de alta demanda es, como se detallará en la sección 2.1.2, el origen mismo del fenómeno de congestión.




Figura 2.1: Representación de una red entre dos computadoras.

El funcionamiento de una red se organiza de manera jerárquica para domar la complejidad

inherente a la comunicación digital. Esta organización se plasma en los llamados modelos de referencia, que dividen el problema de transmitir información en varias capas superpuestas, cada una con responsabilidades claramente acotadas: desde los aspectos puramente físicos de la transmisión (voltajes, pulsos de luz, ondas de radio) hasta la interacción con las aplicaciones que el usuario ve en pantalla. Esta arquitectura en capas permite que un fabricante mejore un componente sin necesidad de rediseñar toda la red, y que tecnologías muy dispares puedan interoperar siempre que respeten los protocolos definidos en cada nivel. El modelo de referencia más utilizado para describir esta organización, el modelo OSI, se desarrolla con mayor profundidad en la sección 2.1.1.

Más allá de cómo se organizan las capas, existe una decisión de diseño fundamental que determina cómo viajan realmente los datos a través de una red: el paradigma de conmutación. En las redes telefónicas tradicionales se empleaba la **conmutación de circuitos**: cuando dos personas iniciaban una llamada, la red reservaba un camino físico dedicado y exclusivo entre ambos extremos durante toda la conversación. Este enfoque garantiza una calidad de servicio constante y predecible, pero resulta profundamente ineficiente desde el punto de vista de la utilización de recursos: si los interlocutores hacen una pausa de diez segundos, el circuito reservado permanece completamente ocioso y ningún otro usuario puede aprovecharlo, incluso si la red entera está saturada de solicitudes en ese instante.

Las redes de computadoras modernas, incluida Internet, optaron por un modelo radicalmente distinto: la **conmutación de paquetes**. En este paradigma, los datos se fragmentan en pequeñas unidades llamadas paquetes o datagramas, cada una encabezada por información de control (dirección de origen, destino, número de secuencia, entre otros campos). Cada paquete viaja de nodo en nodo de manera independiente y sin reservar recursos exclusivos, compartiendo dinámicamente los enlaces con paquetes pertenecientes a otras comunicaciones completamente distintas. Cuando un remitente hace una pausa en su transmisión, otros flujos aprovechan inmediatamente el enlace liberado, lo que multiplica la eficiencia global del sistema comparado con la conmutación de circuitos [5].

Esta compartición estadística de los recursos es, precisamente, la razón por la que Internet puede ofrecer conectividad a miles de millones de dispositivos con una infraestructura física finita. Sin embargo, tiene una contrapartida inevitable: como ningún flujo individual tiene garantizado un ancho de banda exclusivo, si demasiados remitentes transmiten de manera simultánea a través del mismo enlace, la demanda agregada puede superar la capacidad disponible. Es precisamente en este punto —cuando la suma de los flujos que compiten por un recurso compartido excede lo que ese recurso puede entregar— donde se origina el fenómeno que esta tesis busca predecir: la congestión de red, que se define y caracteriza formalmente en la siguiente sección.

Capacidad del enlace: ancho de banda, throughput y utilización

Para poder cuantificar cuándo un enlace se encuentra cerca de su límite, es necesario introducir tres métricas básicas que se emplearán a lo largo de toda la tesis. Cada enlace en una red posee una capacidad máxima teórica de transmisión, denominada **ancho de banda** (*bandwidth*), que se mide en bits por segundo (bps). Un enlace de fibra óptica típico puede ofrecer 1 Gbps, mientras que una conexión inalámbrica doméstica quizás solo alcance 50 Mbps. Esta cifra representa el límite superior teórico del enlace, no la cantidad de datos que

efectivamente circula por él en un momento dado.

El tráfico real que atraviesa el enlace en un instante determinado se conoce como **throughput** o rendimiento efectivo, y su valor siempre es inferior o igual al ancho de banda nominal, ya que factores como la sobrecarga de los encabezados de protocolo, las retransmisiones y el propio comportamiento del tráfico impiden alcanzar el máximo teórico de manera sostenida. La razón entre el throughput observado y el ancho de banda disponible se denomina **factor de utilización**, y constituye una de las métricas más reveladoras sobre el estado de salud de un enlace:

$$U = \frac{\text{Throughput observado}}{\text{Ancho de banda nominal}} \quad (2.1)$$

Mientras el factor de utilización se mantenga en niveles moderados, la red opera con holgura: existe margen suficiente para absorber ráfagas de tráfico sin que se produzcan retrasos perceptibles. Conforme U se aproxima a 1 (es decir, al 100 % de la capacidad), comienzan a manifestarse los síntomas característicos de la congestión, los cuales se explican en detalle a continuación.

2.1.1. Modelo OSI y TCP/IP

El Modelo de Interconexión de Sistemas Abiertos (OSI, *Open Systems Interconnection*), estandarizado por la Organización Internacional de Normalización (ISO) en 1984, constituye un marco conceptual que divide el proceso de comunicación en redes en siete capas funcionales independientes [4]. Cada nivel abstrae un conjunto específico de responsabilidades, desde la transmisión física de bits hasta la interacción con las aplicaciones del usuario. Esta estratificación facilita la interoperabilidad entre equipos de distintos fabricantes y permite analizar los fenómenos de red, como la congestión, dentro de una estructura bien definida. En particular, la gestión de la congestión incide directamente en las capas de transporte y red, donde se regulan el control de flujo, el enrutamiento y la asignación de recursos, aspectos que serán modelados en este trabajo a partir de métricas de utilización.



Figura 2.2: Capas del modelo OSI.

2.1.2. Concepto de congestión

Con las nociones de ancho de banda, throughput y utilización ya establecidas, es posible ahora caracterizar con precisión qué ocurre dentro de una red cuando la demanda de tráfico se aproxima o supera la capacidad disponible de un enlace. A este fenómeno se le denomina **congestión de red**, y constituye el objeto central de estudio de esta tesis.

Qué ocurre dentro de un enrutador

Para entender el origen físico de la congestión es necesario examinar qué sucede dentro de un enrutador o conmutador cuando procesa tráfico. Cada dispositivo de interconexión dispone de pequeñas memorias temporales llamadas **buffers**, donde almacena los paquetes que van llegando mientras esperan ser procesados y reenviados por el enlace de salida correspondiente. Si los paquetes llegan a una tasa inferior a la capacidad del enlace de salida, el buffer apenas se ocupa y los paquetes son despachados casi de inmediato, sin apenas tiempo de espera.

El problema surge cuando, durante un intervalo sostenido, la tasa de llegada de paquetes supera la tasa a la que el enlace de salida puede transmitirlos. En ese escenario, la cola de espera dentro del buffer comienza a crecer progresivamente. Este fenómeno es análogo a lo que ocurre en una caseta de cobro de autopista: mientras los vehículos lleguen a un ritmo menor al que la caseta puede atender, la fila permanece corta y el retraso es mínimo; pero si llegan más vehículos de los que la caseta puede procesar, la fila se alarga sin control y el tiempo de espera se dispara de forma no lineal. Es importante subrayar este último punto: el retraso generado por la congestión **no crece de manera proporcional** al exceso de tráfico, sino que tiende a dispararse de forma abrupta una vez que se cruza cierto umbral de utilización, un comportamiento bien documentado en la teoría de colas aplicada a redes de datos [6].

Latencia y sus componentes

El tiempo total que un paquete tarda en viajar desde que ingresa a la red hasta que llega a su destino se conoce como **latencia** o retardo extremo a extremo, y se compone de cuatro elementos:

- **Tiempo de propagación:** lo que tarda la señal física en recorrer el medio de transmisión (cable, fibra, aire), determinado por la distancia y la velocidad de propagación de la señal.
- **Tiempo de transmisión:** lo que tarda el nodo emisor en colocar todos los bits del paquete sobre el medio físico, el cual depende del tamaño del paquete y del ancho de banda del enlace.
- **Tiempo de procesamiento:** el que cada nodo intermedio invierte en examinar el encabezado del paquete y decidir hacia dónde reenviarlo.
- **Tiempo de encolado:** el tiempo que el paquete permanece esperando dentro del buffer de un enrutador antes de ser transmitido.

En condiciones normales de operación, el tiempo de encolado es prácticamente insignificante frente a los otros tres componentes. Sin embargo, bajo congestión, este componente puede convertirse —y de hecho suele convertirse— en el factor dominante de la latencia total, siendo responsable de la gran mayoría del retraso que experimenta el usuario final.

Jitter: la variabilidad del retraso

Dado que la llegada de paquetes a un enrutador es irregular e impredecible por naturaleza, el tamaño de la cola de espera fluctúa constantemente a lo largo del tiempo. Como consecuencia, la latencia experimentada por paquetes consecutivos de un mismo flujo no es constante, sino que varía de un paquete a otro. Esta variabilidad en el retardo se denomina **jitter**, y resulta particularmente perjudicial para aplicaciones sensibles al tiempo que requieren una entrega de datos a ritmo constante, como las videollamadas, los juegos en línea o la transmisión de audio y video en tiempo real, donde un jitter elevado se traduce en cortes, distorsión o congelamiento de la imagen incluso cuando la latencia promedio parece aceptable.

Pérdida de paquetes y la respuesta reactiva de TCP

Cuando la congestión se agrava lo suficiente, el buffer de un enrutador puede llegar a llenarse por completo. Llegado ese punto, el dispositivo no tiene más opción que descartar los paquetes entrantes que ya no caben en la memoria disponible, un evento conocido como **pérdida de paquetes**. Una tasa de pérdida ocasional puede ser tolerable e incluso pasar desapercibida para el usuario, pero cuando se vuelve frecuente, degrada severamente la calidad de la comunicación.

Es en este punto donde interviene el comportamiento de los protocolos de transporte, particularmente TCP. Este protocolo interpreta la pérdida de paquetes como una señal indirecta de que la red está congestionada, y en respuesta reduce drásticamente su tasa de envío mediante mecanismos de control de congestión [7], para posteriormente incrementarla de manera gradual mientras no detecte nuevas pérdidas. Este mecanismo, formalizado en estándares como el RFC 2914 [8], ha sido fundamental para preservar la estabilidad de Internet durante décadas. No obstante, es crucial notar su naturaleza intrínsecamente **reactiva**: el mecanismo solo se activa *después* de que la congestión ya ha provocado pérdidas reales, momento en el cual la calidad del servicio ya se ha degradado y el usuario final ya ha percibido el problema. Esta limitación reactiva es, precisamente, la motivación central que da origen al enfoque predictivo propuesto en esta tesis.

El cuello de botella

En cualquier ruta que conecte dos nodos de una red, típicamente a través de múltiples enlaces intermedios, existe un concepto adicional relevante: el **cuello de botella** (*bottleneck*). Se trata del enlace con menor capacidad disponible a lo largo de toda la ruta, y es este el que determina la velocidad máxima a la que pueden fluir los datos de extremo a extremo, de manera análoga a como el tramo más estrecho de una tubería limita el caudal total de agua que puede circular por ella, sin importar qué tan anchos sean los demás tramos. Los cuellos de botella son, por definición, los puntos donde la congestión se manifiesta primero y

con mayor intensidad dentro de una red, y por lo tanto son los candidatos naturales sobre los cuales aplicar técnicas de predicción y prevención, como la que se propone en este trabajo.

Definición operativa de congestión para esta tesis

A partir de los elementos anteriores —utilización, buffers, latencia, jitter, pérdida de paquetes y cuellos de botella— es posible ahora formular una definición precisa y, sobre todo, *medible* de congestión, que es la que se adoptará de manera consistente a lo largo de todo el desarrollo metodológico y experimental de esta tesis.

Se dice que un enlace se encuentra en estado de **congestión** cuando su factor de utilización U (Ecuación 2.1) supera un umbral crítico U_{th} durante un intervalo de tiempo sostenido, más allá del cual el comportamiento del sistema deja de ser lineal y comienzan a manifestarse de forma perceptible los síntomas descritos anteriormente: crecimiento acelerado del tiempo de encolado, incremento del jitter y, en los casos más severos, pérdida de paquetes. Formalmente:

$$\text{Congestión} \iff U(t) \geq U_{th} \quad \text{durante un intervalo } [t, t + \Delta t] \quad (2.2)$$

Esta definición operativa presenta dos ventajas fundamentales para los fines de esta investigación. En primer lugar, se apoya en una métrica directamente observable y de fácil recolección de forma pasiva —el factor de utilización—, a diferencia de otras métricas como el jitter o la pérdida de paquetes, que requieren instrumentación más invasiva o cálculos derivados más complejos. En segundo lugar, al tratarse de un umbral cuantitativo y no de una apreciación cualitativa, permite convertir el problema de "predecir congestión" en un problema bien definido de aprendizaje automático: ya sea como una tarea de **regresión** (predecir el valor futuro de $U(t)$) o como una tarea de **clasificación binaria** (predecir si $U(t)$ superará o no el umbral U_{th} en un horizonte temporal determinado), ambos enfoques que se explorarán y compararán en los capítulos metodológico y experimental de este trabajo.

Es importante reconocer, sin embargo, que esta definición constituye una simplificación deliberada de un fenómeno inherentemente multifactorial. Como se mencionó en la sección de alcances y limitaciones, otras dimensiones de la congestión —como el jitter o la tasa de pérdida de paquetes— no son modeladas de forma directa por el prototipo desarrollado en esta tesis, aunque su comprensión teórica, expuesta en esta sección, resulta indispensable para justificar por qué la utilización constituye un proxy razonable y suficientemente informativo del estado de congestión de un enlace.

2.1.3. Métricas de rendimiento

En la sección anterior se explicó *qué* son la utilización, la latencia, el jitter y la pérdida de paquetes, y *por qué* aparecen como consecuencia de la congestión. Corresponde ahora precisar *cómo* se cuantifica formalmente cada una de estas métricas, qué unidades emplean y mediante qué mecanismos se obtienen en la práctica, ya que estas definiciones son las que se emplearán posteriormente para construir el conjunto de variables (*features*) que alimentarán los modelos de Machine Learning propuestos en esta tesis.

Utilización del enlace

Como se estableció en la Ecuación 2.1, la utilización U es la razón entre el throughput observado y el ancho de banda nominal del enlace. En términos de instrumentación, esta métrica se obtiene típicamente mediante el protocolo SNMP (*Simple Network Management Protocol*), consultando periódicamente los contadores de octetos entrantes y salientes de una interfaz de red (`ifInOctets` e `ifOutOctets` de la MIB-II) [4]. Dado que estos contadores son acumulativos, el throughput en un intervalo $[t_1, t_2]$ se calcula como la diferencia entre lecturas consecutivas dividida entre el tiempo transcurrido:

$$\text{Throughput}(t_1, t_2) = \frac{8 \times (\text{Octetos}(t_2) - \text{Octetos}(t_1))}{t_2 - t_1} \quad (2.3)$$

donde el factor 8 convierte de bytes a bits, ya que el ancho de banda se expresa convencionalmente en bits por segundo. La granularidad del muestreo (por ejemplo, cada 30 segundos, 1 minuto o 5 minutos) determina la resolución temporal con la que posteriormente se podrá detectar y predecir la congestión, y constituye una decisión metodológica que se abordará en el Capítulo 4.

Latencia (RTT)

La latencia de ida y vuelta, o *Round-Trip Time* (RTT), es el tiempo que transcurre entre el envío de un paquete y la recepción de su respuesta. Se mide de forma activa mediante herramientas como `ping` (que emplea paquetes ICMP *Echo Request/Reply*) o mediante el análisis de las marcas de tiempo (*timestamps*) del protocolo TCP durante el establecimiento de una conexión (*three-way handshake*) [5]. Formalmente:

$$\text{RTT} = t_{\text{recepción}} - t_{\text{envío}} \quad (2.4)$$

En la práctica no se trabaja con una sola medición de RTT, sino con una serie de mediciones sucesivas, ya que es precisamente la variabilidad entre estas mediciones consecutivas la que da origen al jitter, descrito a continuación.

Jitter

A diferencia de la explicación conceptual ofrecida en la sección anterior, aquí se presenta la definición formal adoptada por el estándar RFC 3550, que especifica el protocolo RTP (*Real-time Transport Protocol*) utilizado ampliamente en aplicaciones de voz y video sobre IP [9]. Dicho estándar define el jitter como la variación estadística en el tiempo de llegada entre paquetes consecutivos, y propone un estimador de primer orden que se actualiza de forma incremental con cada nuevo paquete recibido:

$$J(i) = J(i-1) + \frac{|D(i-1, i)| - J(i-1)}{16} \quad (2.5)$$

donde $D(i-1, i)$ representa la diferencia en los tiempos de tránsito relativos entre dos paquetes consecutivos $i-1$ e i , calculada como:

$$D(i-1, i) = (R_i - R_{i-1}) - (S_i - S_{i-1}) \quad (2.6)$$

siendo R_i el instante de llegada del paquete i en el receptor y S_i la marca de tiempo con la que dicho paquete fue enviado por el emisor. El factor $1/16$ actúa como una ganancia de suavizado que da lugar a un estimador con buen equilibrio entre estabilidad estadística y capacidad de reacción ante cambios súbitos, evitando que picos aislados distorsionen la medición general [9]. Esta es la definición de jitter que se adoptará como referencia en esta tesis en caso de emplearse como variable adicional de análisis.

Pérdida de paquetes

La tasa de pérdida de paquetes (*packet loss rate*) se expresa como el porcentaje de paquetes enviados que nunca llegan a su destino, respecto del total de paquetes transmitidos en un intervalo de observación:

$$P_{\text{loss}} = \frac{\text{Paquetes enviados} - \text{Paquetes recibidos}}{\text{Paquetes enviados}} \times 100 \% \quad (2.7)$$

Esta métrica puede obtenerse de dos maneras. La primera es de forma **activa**, inyectando tráfico de prueba (por ejemplo, mediante herramientas como **iperf** o series de solicitudes ICMP) y contabilizando cuántas respuestas se reciben de vuelta. La segunda es de forma **pasiva**, consultando directamente los contadores de descarte que los propios dispositivos de red exponen a través de SNMP (como **ifInDiscards** o **ifOutDiscards**), sin necesidad de generar tráfico adicional que pudiera, irónicamente, contribuir a la propia congestión que se busca medir [4]. Esta segunda aproximación resulta preferible en el contexto de esta tesis, dado que el planteamiento del problema exige una recolección de datos estrictamente pasiva.

Throughput vs. Goodput

Conviene distinguir con precisión entre dos términos que suelen confundirse. El **throughput**, definido en la Ecuación 2.3, contabiliza la totalidad de los bits que atraviesan el enlace en un intervalo de tiempo, incluyendo los encabezados de los distintos protocolos (Ethernet, IP, TCP/UDP) y cualquier paquete retransmitido debido a pérdidas previas. El **goodput**, en cambio, contabiliza únicamente los bits de datos útiles a nivel de aplicación que fueron entregados exitosamente, excluyendo dicho overhead de protocolo:

$$\text{Goodput} = \frac{\text{Bits útiles entregados a la capa de aplicación}}{\text{Tiempo total de transmisión}} \quad (2.8)$$

Bajo condiciones de congestión severa, es posible observar un throughput aparentemente estable mientras el goodput cae drásticamente, ya que una proporción creciente del tráfico corresponde a retransmisiones de paquetes perdidos en lugar de datos nuevos. Esta distinción resulta relevante para esta tesis porque un modelo que solo observe throughput podría no detectar que la red ya se encuentra operando de manera ineficiente por efecto de la congestión.

Disponibilidad

Finalmente, la **disponibilidad** (*availability*) de un enlace o servicio de red se define como la proporción de tiempo durante la cual dicho recurso se encuentra operativo y accesible, respecto del tiempo total de observación:

$$\text{Disponibilidad} = \frac{\text{Tiempo operativo}}{\text{Tiempo operativo} + \text{Tiempo de inactividad}} \times 100 \% \quad (2.9)$$

Si bien la disponibilidad se asocia tradicionalmente con fallos de hardware o interrupciones del servicio más que con la congestión en sí misma, ambos fenómenos están relacionados: una congestión suficientemente severa y sostenida puede degradar la calidad del servicio hasta un punto en que, desde la perspectiva del usuario final, resulta indistinguible de una interrupción total. Por esta razón, y dado que fue contemplada explícitamente entre los objetivos específicos de este trabajo, la disponibilidad se incorpora como una métrica complementaria dentro del conjunto de datos de operación a recopilar.

Síntesis de métricas

La Tabla 2.1 sintetiza las métricas descritas en esta sección, sus unidades y su método de obtención, y constituye la base sobre la cual se construirá el conjunto de variables de entrada (*features*) del sistema de predicción propuesto en el Capítulo 4.

Métrica	Unidad	Ecuación	Método de obtención
Utilización	Adimensional (%)	2.1	SNMP (pasivo)
Throughput	bits/s	2.3	SNMP (pasivo)
Latencia (RTT)	ms	2.4	ICMP / TCP timestamps (activo)
Jitter	ms	2.5	RTCP / estimación RFC 3550
Pérdida de paquetes	%	2.7	SNMP (pasivo) / probes (activo)
Goodput	bits/s	2.8	Derivado de throughput
Disponibilidad	%	2.9	Monitoreo continuo

Cuadro 2.1: Resumen de métricas de rendimiento de red utilizadas en esta tesis.

2.2. Técnicas de Machine Learning aplicables

Una vez establecidos los fundamentos de redes de computadoras y caracterizado formalmente el fenómeno de la congestión, corresponde ahora presentar el conjunto de herramientas metodológicas que esta tesis emplea para abordar el problema de predicción planteado: las técnicas de Machine Learning (ML). Esta sección no pretende ser un tratado exhaustivo de aprendizaje automático, sino una revisión dirigida y suficiente de los conceptos, paradigmas y modelos específicos que resultan pertinentes para la tarea de predecir series temporales de utilización de red, y que serán empleados e implementados en los capítulos de Metodología (Capítulo 4) y Desarrollo (Capítulo 5).

2.2.1. Aprendizaje supervisado: regresión vs clasificación

El aprendizaje automático se organiza tradicionalmente en tres grandes paradigmas: el aprendizaje supervisado, en el que el modelo aprende a partir de ejemplos previamente etiquetados con la respuesta correcta; el aprendizaje no supervisado, en el que el modelo busca patrones o estructuras ocultas en datos sin etiquetar; y el aprendizaje por refuerzo, en el que

un agente aprende a partir de la interacción con un entorno y de las recompensas obtenidas. El problema de predicción de congestión planteado en esta tesis se enmarca de manera natural dentro del **aprendizaje supervisado**, ya que se dispone de datos históricos de operación de red (las variables de entrada o *features*, como utilización, latencia o pérdida de paquetes en instantes pasados) junto con el valor real observado que se desea predecir (la utilización futura del enlace).

Dentro del aprendizaje supervisado, y de acuerdo con la naturaleza de la variable que se busca predecir, es posible distinguir dos tareas fundamentales:

- **Regresión:** la variable objetivo es continua. En el contexto de esta tesis, esto correspondería a predecir directamente el valor futuro del factor de utilización $U(t + h)$ para un horizonte de predicción h , expresado como un número real entre 0 y 1.
- **Clasificación:** la variable objetivo es discreta o categórica. En este caso, correspondería a predecir si el enlace se encontrará o no en estado de congestión en el horizonte h , de acuerdo con la definición operativa formulada en la Ecuación 2.2 —es decir, si $U(t + h) \geq U_{th}$ —, reduciendo el problema a una clasificación binaria (congestión / no congestión).

Ambos enfoques no son mutuamente excluyentes, sino complementarios: un modelo de regresión ofrece información más rica (el valor exacto esperado de utilización), mientras que uno de clasificación ofrece una respuesta más directamente accionable para un sistema de alertas (sí/no hay riesgo de congestión). Por esta razón, en esta tesis se explorará la formulación del problema bajo ambos enfoques según el modelo empleado, tal como se detalla en las siguientes subsecciones.




Figura 2.3: Ubicación del problema de predicción de congestión dentro de los paradigmas de Machine Learning.

2.2.2. Modelos de series temporales (ARIMA)

El modelo **ARIMA** (*AutoRegressive Integrated Moving Average*), desarrollado dentro del marco metodológico propuesto por Box y Jenkins, constituye uno de los enfoques estadísticos más consolidados para el análisis y predicción de series temporales [10]. Su nombre resume sus tres componentes constitutivos:

- **AR (AutoRegresivo)**: el valor de la serie en un instante dado se modela como una combinación lineal de sus propios valores pasados, con un orden p que indica cuántos rezagos (*lags*) se consideran.
- **I (Integrado)**: aplica un proceso de diferenciación de orden d a la serie original para eliminar tendencias y volverla estacionaria, requisito necesario para que el modelo funcione correctamente.
- **MA (Media Móvil)**: el valor de la serie se modela también en función de los errores de predicción pasados, con un orden q .

Un modelo ARIMA se denota comúnmente como $ARIMA(p, d, q)$, y se expresa formalmente como:

$$\left(1 - \sum_{i=1}^p \phi_i L^i\right) (1 - L)^d X_t = \left(1 + \sum_{i=1}^q \theta_i L^i\right) \varepsilon_t \quad (2.10)$$

donde X_t es la serie temporal de interés (en este caso, la utilización del enlace en el instante t), L es el operador de rezago, ϕ_i y θ_i son los coeficientes autorregresivos y de media móvil respectivamente, y ε_t representa el término de error o ruido blanco. Este modelo resulta especialmente útil como **línea base** (*baseline*) dentro de esta tesis: al tratarse de un método estadístico clásico, bien establecido y computacionalmente económico, permite establecer un punto de referencia mínimo de desempeño contra el cual comparar la capacidad predictiva de los modelos de aprendizaje automático más sofisticados que se presentan a continuación.

2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)

A diferencia de ARIMA, que asume relaciones lineales explícitas entre los valores pasados y futuros de la serie, los modelos de aprendizaje automático clásico son capaces de capturar relaciones no lineales entre múltiples variables de entrada simultáneamente, lo cual resulta particularmente valioso cuando se dispone de varias métricas de red (utilización, latencia, pérdida de paquetes, hora del día, día de la semana, entre otras) como posibles predictores.

Random Forest es un método de aprendizaje por conjunto (*ensemble*) que construye una multitud de árboles de decisión durante el entrenamiento, cada uno entrenado sobre una muestra aleatoria de los datos y considerando un subconjunto aleatorio de variables en cada división del árbol [11]. Para tareas de regresión, la predicción final del bosque se obtiene promediando las predicciones individuales de todos los árboles que lo componen:

$$\hat{y} = \frac{1}{T} \sum_{i=1}^T h_i(x) \quad (2.11)$$

donde T es el número total de árboles y $h_i(x)$ es la predicción del árbol i -ésimo para la entrada x . Esta estrategia de combinar múltiples predictores "débiles" en un predictor colectivo robusto reduce significativamente el riesgo de sobreajuste (*overfitting*) comparado con un único árbol de decisión, y ofrece además una ventaja adicional relevante para esta tesis: la posibilidad de calcular la **importancia relativa** de cada variable de entrada, lo cual permite identificar qué métricas de red resultan más informativas para predecir la congestión.

Por su parte, **SVR** (*Support Vector Regression*) es la adaptación al problema de regresión de las Máquinas de Vectores de Soporte (SVM), y busca encontrar una función que se ajuste a los datos permitiendo un margen de tolerancia ε , penalizando únicamente aquellas predicciones cuyo error exceda dicho margen. Su capacidad para emplear funciones de *kernel* (lineales, polinomiales o de base radial) le permite modelar relaciones no lineales complejas entre las variables de red y la utilización futura del enlace, constituyendo una alternativa adicional dentro de la familia de modelos de aprendizaje automático clásico a evaluar en esta tesis.

2.2.4. Modelos de Deep Learning (LSTM, GRU)

Las redes neuronales recurrentes (RNN) fueron diseñadas específicamente para procesar datos secuenciales, manteniendo una suerte de "memoria interna" que se actualiza en cada paso temporal. Sin embargo, las RNN convencionales sufren de un problema conocido como el desvanecimiento del gradiente (*vanishing gradient*), que les impide aprender de manera efectiva dependencias que abarcan largos periodos de tiempo —una limitación especialmente relevante para el tráfico de red, donde los patrones de congestión pueden depender de comportamientos observados varios minutos u horas atrás.

Las **LSTM** (*Long Short-Term Memory*) fueron propuestas precisamente para resolver esta limitación, mediante la introducción de una estructura interna de *compuertas* (*gates*) que regulan de manera explícita qué información se conserva, se actualiza o se descarta a lo largo del tiempo [12]. Cada unidad LSTM mantiene un estado de celda c_t que actúa como memoria de largo plazo, y tres compuertas —de olvido, de entrada y de salida— que controlan el flujo de información:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{compuerta de olvido}) \quad (2.12)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{compuerta de entrada}) \quad (2.13)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{compuerta de salida}) \quad (2.14)$$

donde σ es la función de activación sigmoide, x_t es la entrada en el instante t , h_{t-1} es el estado oculto anterior, y W y b son los pesos y sesgos aprendidos durante el entrenamiento. Esta arquitectura permite a la red aprender de forma selectiva qué eventos pasados —por ejemplo, una ráfaga de sincronización de Nextcloud ocurrida varios minutos atrás— siguen siendo relevantes para predecir el estado de la red en el presente.

Las **GRU** (*Gated Recurrent Units*) constituyen una variante simplificada de las LSTM, propuesta posteriormente con el objetivo de reducir la complejidad computacional del modelo sin sacrificar significativamente su capacidad de capturar dependencias temporales de largo plazo [13]. Las GRU combinan las compuertas de olvido y entrada en una única *compuerta de actualización*, y prescinden del estado de celda independiente que caracteriza a las LSTM, resultando en un modelo con menos parámetros entrenables y, por tanto, potencialmente más eficiente de entrenar sobre conjuntos de datos de tamaño moderado como los descritos en la Sección 4.4. La comparación entre LSTM y GRU en cuanto a precisión y costo computacional se abordará empíricamente en el Capítulo 6 de esta tesis.

2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)

Para poder comparar de manera objetiva el desempeño de los distintos modelos presentados en esta sección —ARIMA, Random Forest, SVR, LSTM y GRU— es necesario definir métricas cuantitativas de error, aplicables tanto a la fase de validación como a la comparación final de resultados en el Capítulo 6. Sea y_i el valor real observado, $\hat{y}_i$ el valor predicho por el modelo, y n el número total de observaciones evaluadas.

RMSE (*Root Mean Squared Error*, raíz del error cuadrático medio):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.15)$$

Al elevar al cuadrado cada error antes de promediar, el RMSE penaliza de manera desproporcionada los errores grandes, lo cual resulta conveniente en el contexto de esta tesis: un modelo que falle de forma drástica en predecir un evento de congestión severa es considerablemente más problemático que uno con pequeños errores distribuidos de manera uniforme.

MAE (*Mean Absolute Error*, error absoluto medio):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.16)$$

A diferencia del RMSE, el MAE pondera todos los errores de manera lineal e igualitaria, por lo que resulta menos sensible a valores atípicos (*outliers*) y ofrece una interpretación más directa: representa, en promedio, cuánto se equivoca el modelo en las mismas unidades que la variable original (en este caso, puntos porcentuales de utilización).

MAPE (*Mean Absolute Percentage Error*, error porcentual absoluto medio):

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2.17)$$

El MAPE expresa el error como un porcentaje relativo al valor real, lo que facilita su interpretación independientemente de la escala de la variable y permite comparar el desempeño de un mismo modelo entre el dataset primario y el dataset de validación externa (MAWI), a pesar de que ambos operan a escalas de tráfico sustancialmente distintas, tal como se estableció en la Sección 4.4. Como limitación, esta métrica no está definida cuando $y_i = 0$, situación que deberá considerarse durante su implementación si la utilización del enlace llegara a registrar valores nulos en algún intervalo.

La Tabla 2.2 sintetiza los cinco modelos presentados en esta sección, contrastando su naturaleza, complejidad y tipo de relación que son capaces de capturar, como punto de partida para la justificación metodológica que se desarrollará en el Capítulo 4.

Modelo	Paradigma	Relaciones	Complejidad
ARIMA	Estadístico clásico	Lineales	Baja
Random Forest	ML clásico (ensemble)	No lineales	Media
SVR	ML clásico (kernel)	No lineales	Media
LSTM	Deep Learning (RNN)	No lineales, largo plazo	Alta
GRU	Deep Learning (RNN)	No lineales, largo plazo	Media-Alta

Cuadro 2.2: Resumen comparativo de los modelos de predicción considerados en esta tesis.

Capítulo 3

Estado del Arte

- 3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos
- 3.2. Predicción de tráfico/congestión con Machine Learning clásico
- 3.3. Predicción con Deep Learning
- 3.4. Herramientas de monitoreo y datasets utilizados
- 3.5. Síntesis del estado del arte y brecha a cubrir

Capítulo 4

Metodología

4.1. Tipo de investigación

4.2. Definición operativa de congestión

4.3. Descripción de las métricas a utilizar

4.4. Fuente de datos

Para el desarrollo de esta tesis se adoptó una estrategia híbrida de recolección de datos, combinando una fuente primaria de tráfico real capturado de forma pasiva en una red administrada directamente por el autor, con una fuente secundaria de validación externa proveniente de un archivo académico de tráfico de Internet ampliamente reconocido. Esta combinación busca equilibrar dos necesidades que, de manera aislada, ningún dataset por sí solo podría satisfacer plenamente: por un lado, la posibilidad de definir con precisión el proceso de recolección, las métricas capturadas y el contexto operativo del enlace bajo estudio; y por otro, la necesidad de validar que los modelos desarrollados no se sobreajustan a las particularidades de un único escenario, sino que son capaces de generalizar su capacidad predictiva a condiciones de tráfico distintas en naturaleza y escala.

Dataset primario: red administrada del cliente

La fuente primaria de datos proviene de una red privada residencial/PYME sobre la cual el autor tiene acceso administrativo completo, en el contexto de un proyecto de despliegue de infraestructura previamente desarrollado. Dicha red opera bajo un enrutador MikroTik que concentra y gestiona simultáneamente múltiples servicios que compiten por el mismo enlace de salida a Internet: un sistema de videovigilancia con grabación continua (NVR), tráfico residencial de uso cotidiano, la interconexión hacia el proveedor de servicios de Internet (ISP) a través de una red óptica pasiva (OLT), y, más recientemente, un servicio de almacenamiento en la nube autoalojado (Nextcloud) accesible de forma remota mediante una VPN SSTP. Esta coexistencia de servicios con patrones de tráfico heterogéneos —tráfico constante y de bajo volumen por parte de las cámaras, ráfagas esporádicas de alto volumen durante

sincronizaciones de archivos en la nube, y patrones de uso residencial con picos previsibles en determinadas franjas horarias— constituye un escenario particularmente propicio para el estudio de la congestión, ya que no se trata de tráfico artificial o simulado, sino de la operación real y cotidiana de una red con múltiples fuentes de demanda concurrente.

La recolección de datos sobre esta red se realizará de manera estrictamente pasiva, evitando en todo momento la captura o inspección del contenido (*payload*) de las comunicaciones, y limitándose exclusivamente a metadatos de tráfico agregados: utilización del enlace, obtenida mediante consultas periódicas al protocolo SNMP sobre los contadores de la interfaz WAN del enrutador; y latencia y pérdida de paquetes, obtenidas mediante mediciones activas complementarias hacia un destino externo estable, conforme a las definiciones formales establecidas en la Sección 2.1.3. El periodo de recolección planificado abarca dos meses continuos de operación, con una granularidad de muestreo de un minuto, lo cual permite capturar tanto los patrones cíclicos de uso diario y semanal como los eventos de saturación puntual que resultan de interés central para esta investigación.

Es importante señalar que, dado que los datos provienen de la infraestructura de un tercero, se obtuvo la autorización explícita del propietario de la red para realizar el monitoreo pasivo de metadatos de tráfico con fines exclusivamente académicos, en línea con buenas prácticas de investigación en redes de computadoras que involucran datos de operación reales

Dataset secundario: MAWI Working Group Traffic Archive

Como fuente de validación externa se empleará el **MAWI Working Group Traffic Archive**, un repositorio de trazas de tráfico mantenido de forma continua desde 2006 por el proyecto WIDE, que captura de manera diaria el tráfico del enlace de tránsito entre la red académica WIDE y su proveedor ascendente en Tokio, Japón [14]. A diferencia del dataset primario, que corresponde a una red de escala reducida con un puñado de servicios concurrentes, las trazas de MAWI capturan tráfico agregado de un enlace de tránsito de gran escala (entre 1 y 10 Gbps), compuesto por miles de flujos simultáneos provenientes de múltiples organizaciones y aplicaciones. Las direcciones IP contenidas en estas trazas se encuentran anonimizadas mediante un esquema que preserva la estructura de prefijos de red (*prefix-preserving anonymization*, mediante el algoritmo Crypto-PAn), lo cual elimina cualquier posibilidad de identificar usuarios individuales sin comprometer la utilidad analítica de los datos para el estudio de patrones agregados de tráfico.

La incorporación de este segundo dataset responde a una limitación reconocida en la literatura sobre predicción de tráfico de red: los modelos entrenados y evaluados sobre una única fuente de datos tienden a mostrar un desempeño optimista que no necesariamente se sostiene cuando se exponen a condiciones de tráfico distintas a las observadas durante el entrenamiento. Al validar los modelos desarrollados en esta tesis sobre las trazas de MAWI —de una naturaleza y escala sustancialmente distinta a la del dataset primario—, es posible obtener evidencia más robusta sobre la capacidad de generalización de los enfoques de Machine Learning propuestos, más allá de las particularidades de un único escenario de red.

Dado que las trazas de MAWI se distribuyen en formato de captura de paquetes (*.pcap*) y no como series temporales de utilización previamente agregadas, fue necesario un procesa-

miento adicional para derivar de ellas las mismas métricas empleadas en el dataset primario. Este procesamiento se describe con mayor detalle en la Sección ?? (Preprocesamiento de datos).

Consideraciones éticas y de privacidad

En ambos casos, la recolección y el procesamiento de los datos se rigen por un principio de minimización: se capturan y almacenan únicamente los metadatos estrictamente necesarios para el análisis de utilización, latencia y pérdida de paquetes, sin acceder en ningún momento al contenido de las comunicaciones transportadas. En el caso del dataset primario, se cuenta con la autorización expresa del propietario de la infraestructura; en el caso de MAWI, el uso de los datos se limita a fines de investigación, en cumplimiento con los términos de uso establecidos por el propio archivo, los cuales explícitamente restringen su empleo a propósitos académicos y prohíben cualquier acción que comprometa la privacidad de los usuarios cuyo tráfico fue originalmente capturado.

4.5. Preprocesamiento de datos

4.6. Modelos a implementar y justificación de su elección

4.7. Métricas de evaluación del modelo

4.8. Herramientas y entorno

Capítulo 5

Desarrollo e Implementación

- 5.1. Obtención y exploración del dataset
- 5.2. Preprocesamiento
- 5.3. Construcción del modelo ARIMA
- 5.4. Construcción del modelo Random Forest
- 5.5. Construcción del modelo LSTM

Capítulo 6

Resultados y Discusión

- 6.1. Resultados de ARIMA
- 6.2. Resultados de Random Forest
- 6.3. Resultados de LSTM
- 6.4. Comparativa de modelos
- 6.5. Discusión

Capítulo 7

Conclusiones

7.1. Cumplimiento de objetivos

7.2. Contribuciones

7.3. Limitaciones del estudio

Referencias bibliográficas

Bibliografía

- [1] Cisco Systems, “Cisco annual internet report (2018–2023) white paper,” Cisco, Tech. Rep., 2020, consultado el 25 de mayo de 2026. [Online]. Available: <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>
- [2] R. Boutaba, M. A. Salahuddin, N. Limam, S. Ayoubi, N. Shahriar, F. Estrada-Solano, and O. M. Caicedo, “A comprehensive survey on machine learning for networking: evolution, applications and research opportunities,” *Journal of Internet Services and Applications*, vol. 9, no. 1, p. 16, 2018.
- [3] J. Zhang, Y. Liu, Z. Li, and Y. Lu, “Network traffic prediction using deep learning: An experimental study,” in *2020 IEEE 6th International Conference on Computer and Communications (ICCC)*, 2020, pp. 1320–1325.
- [4] A. S. Tanenbaum and D. J. Wetherall, *Computer Networks*, 5th ed. Boston: Pearson Prentice Hall, 2011.
- [5] J. F. Kurose and K. W. Ross, *Computer Networking: A Top-Down Approach*, 7th ed. Boston: Pearson, 2017.
- [6] L. Kleinrock, *Queueing Systems, Volume II: Computer Applications*. New York: John Wiley & Sons, 1976.
- [7] V. Jacobson, “Congestion avoidance and control,” in *Symposium proceedings on Communications architectures and protocols (SIGCOMM ’88)*, vol. 18, no. 4. Stanford, CA, USA: ACM, 1988, pp. 314–329.
- [8] S. Floyd, “Congestion control principles,” RFC 2914, Internet Engineering Task Force (IETF), BCP 41, September 2000. [Online]. Available: <https://www.rfc-editor.org/rfc/rfc2914>
- [9] H. Schulzrinne, S. Casner, R. Frederick, and V. Jacobson, “Rtp: A transport protocol for real-time applications,” RFC 3550, Internet Engineering Task Force (IETF), July 2003. [Online]. Available: <https://www.rfc-editor.org/rfc/rfc3550>
- [10] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ: John Wiley & Sons, 2015.
- [11] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

- [12] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [13] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, “Learning phrase representations using rnn encoder-decoder for statistical machine translation,” in *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Doha, Qatar, 2014, pp. 1724–1734.
- [14] MAWI Working Group, “Mawi working group traffic archive,” WIDE Project, consultado en 2026. [Online]. Available: <https://mawi.wide.ad.jp/mawi/>

Apéndice A

Código fuente de ejemplos críticos

Apéndice B

Capturas de pantalla adicionales