

Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias de la Computación



T E S I S

**“Predicción de congestión en redes de computadoras
utilizando técnicas de Machine Learning”**

Presenta:

Ricardo Valera Martínez

Para obtener el grado de:

Licenciatura en Ingeniería en Ciencias de la Computación

Director: **Mauro Alberto López Muñoz**

Codirector: **Guillermo Colorado Jiménez**

Puebla, Pue., Febrero 2026

Índice general

1. Introducción	6
1.1. Planteamiento del problema	6
1.2. Objetivos	7
1.2.1. Objetivo General	7
1.2.2. Objetivos Específicos	7
1.3. Justificación	8
1.4. Alcances y Limitaciones	9
2. Marco Teórico	11
2.1. Fundamentos de redes de computadoras	11
2.1.1. Modelo OSI y TCP/IP	11
2.1.2. Concepto de congestión	11
2.1.3. Métricas de rendimiento	12
2.2. Técnicas de Machine Learning aplicables	12
2.2.1. Aprendizaje supervisado: regresión vs clasificación	12
2.2.2. Modelos de series temporales (ARIMA)	12
2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)	12
2.2.4. Modelos de Deep Learning (LSTM, GRU)	12
2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)	12
3. Estado del Arte	13
3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos . .	13
3.2. Predicción de tráfico/congestión con Machine Learning clásico	13
3.3. Predicción con Deep Learning	13
3.4. Herramientas de monitoreo y datasets utilizados	13
3.5. Síntesis del estado del arte y brecha a cubrir	13
4. Metodología	14
4.1. Tipo de investigación	14
4.2. Definición operativa de congestión	14
4.3. Descripción de las métricas a utilizar	14
4.4. Fuente de datos	14
4.5. Preprocesamiento de datos	14
4.6. Modelos a implementar y justificación de su elección	14
4.7. Métricas de evaluación del modelo	14

4.8. Herramientas y entorno	14
5. Desarrollo e Implementación	15
5.1. Obtención y exploración del dataset	15
5.2. Preprocesamiento	15
5.3. Construcción del modelo ARIMA	15
5.4. Construcción del modelo Random Forest	15
5.5. Construcción del modelo LSTM	15
6. Resultados y Discusión	16
6.1. Resultados de ARIMA	16
6.2. Resultados de Random Forest	16
6.3. Resultados de LSTM	16
6.4. Comparativa de modelos	16
6.5. Discusión	16
7. Conclusiones	17
7.1. Cumplimiento de objetivos	17
7.2. Contribuciones	17
7.3. Limitaciones del estudio	17
Referencias bibliográficas	18
A. Código fuente de ejemplos críticos	20
B. Capturas de pantalla adicionales	21

Índice de figuras

Índice de cuadros

DEDICATORIA

*A mi padre, **Ricardo Valera Hernández**, por ser el pilar constante en cada etapa de mi formación, por su paciencia, su apoyo incondicional y por nunca dejar de creer en mí incluso cuando yo dudaba, por su ejemplo de responsabilidad y esfuerzo, por enseñarme que el trabajo honesto y la perseverancia son el camino para alcanzar cualquier meta.*

*A mi madre, **María Margarita Irma Martínez Pérez**, por ser la guía y el apoyo incondicional que hizo posible este trayecto. Gracias por su confianza infinita, por sus palabras que siempre supieron darme fuerza y por estar presente en cada paso de mi formación profesional. Este trabajo es testimonio de su esfuerzo y dedicación constante en mi vida.*

*A mi novia, **Vanessa F. Linarte Castañeda**, por su amor, su comprensión y su compañía en los momentos de cansancio y dificultad, por motivarme a seguir adelante cuando parecía imposible y por ser parte fundamental de este logro.*

*A mi hermano menor, **Emilio Valera Martínez**, por su complicidad y apoyo en los momentos de distracción y de enfoque. Gracias por estar ahí, por los consejos y por ser un compañero constante en este camino.*

*Al **Sr. Héctor H. Linarte** y la **Sra. Cristina E. Castañeda**, por recibirme en su familia como a un hijo más, por sus palabras de aliento y por el apoyo incondicional brindado durante este proceso. Su confianza y cariño fueron fundamentales para mantener el ánimo en la recta final.*

*A mi director de tesis, el **Mtro. Mauro Alberto López Muñoz**, y a mi codirector, el **Mtro. Guillermo Colorado Jiménez**, por su invaluable guía, su paciencia y por compartir su conocimiento para llevar este proyecto a buen puerto.*

Capítulo 1

Introducción

“El futuro de las redes de computadoras no solo depende de transmitir datos más rápido, sino de hacerlo de manera inteligente.”

La evolución en las redes de computadoras ha permitido el desarrollo de una gran cantidad de servicios y aplicaciones que forman parte de la vida cotidiana, desde la navegación web y las plataformas de comunicación, hasta los sistemas distribuidos, la computación en la nube y el intercambio masivo de información en tiempo real. Debido a este crecimiento constante en la cantidad de dispositivos conectados y el volumen de tráfico generado, las redes modernas enfrentan cada vez mayores desafíos relacionados con el rendimiento, la disponibilidad y la calidad del servicio.

1.1. Planteamiento del problema

Vivimos en una era digital en la que la conectividad se ha convertido en un servicio esencial, tan fundamental como la electricidad o el agua corriente. Desde las videollamadas que nos acercan a nuestros familiares y colegas, hasta las plataformas de streaming que nos ofrecen entretenimiento bajo demanda, pasando por la explosión del internet de las cosas (IoT) que llena nuestros hogares y ciudades de sensores inteligentes, gran parte de nuestra vida cotidiana depende de un flujo constante e ininterrumpido de datos. Según el informe *Cisco Annual Internet Report (2018–2023)*, el número de usuarios de Internet a nivel mundial pasó de 3900 millones en 2018 a 5300 millones en 2023, mientras que los dispositivos conectados a redes IP aumentaron de 18 400 millones a 29 300 millones en el mismo período [1].

Las redes de computadoras son el tejido que sostiene cambios inminentes en la industria. Sin embargo, no son un recurso infinito: cada enrutador, cada conmutador y cada enlace de fibra óptica tiene una capacidad limitada. Cuando la demanda de transmisión de datos supera esa capacidad se produce un fenómeno conocido como congestión de red. En términos sencillos (más adelante se abordará una definición apropiada para este trabajo), la congestión es el equivalente digital a un embotellamiento en una autopista: demasiados coches (paquetes de datos) intentando circular al mismo tiempo por un carril con aforo máximo. Las consecuencias se vuelven inmediatas y totalmente perceptibles para el usuario final: videollamadas

que se congelan, páginas web que cargan con lentitud, archivos que no terminan de descargarse o, en el peor de los casos, se pierde totalmente la conexión. En entornos críticos como hospitales, sistemas de redes financieras o redes industriales, estos fallos se traducen en pérdidas económicas millonarias o incluso riesgos para la seguridad de las personas.

Tradicionalmente, la gestión de redes ha tenido un enfoque reactivo: los administradores monitorizan equipos y, cuando detectan que un enlace está saturado, toman medidas correctivas como redirigir el tráfico, limitar ciertas aplicaciones o aumentar la capacidad del enlace. Este modo de actuar, aunque ha resultado funcional durante décadas, presenta una limitación fundamental: actúa después de que el problema ya ha comenzado a degradar la calidad del servicio. Pensemos en un coche autónomo que necesita tomar decisiones en milisegundos en tiempo real o en un cirujano operando a distancia mediante un robot; reaccionar después ya no es una opción, se necesita anticipación.

En este contexto, surge una pregunta clave: ¿es posible predecir que un enlace se va a congestionar con suficiente antelación para que un sistema automático o un administrador pueda evitarlo? La respuesta a esta pregunta pasa por abandonar la simple monitorización para adentrarse en el terreno del análisis predictivo. Aquí es donde entran en juego las técnicas de Machine Learning (ML), una rama de la inteligencia artificial que permite a las máquinas aprender patrones a partir de datos históricos y realizar predicciones sin ser programadas explícitamente para cada escenario.

El presente trabajo de tesis se sitúa justo en esta intersección entre las redes de computadoras y la inteligencia artificial. El objetivo central es desarrollar un sistema basado en técnicas de Machine Learning que sea capaz de predecir la congestión en un enlace de red a partir del análisis de métricas de tráfico obtenidas de forma pasiva. En lugar de limitarnos a reaccionar cuando la utilización ya está en niveles críticos, busco construir un modelo que pueda alertar con varios minutos de antelación: “Atención: este enlace alcanzará el 85 % de su capacidad; toma medidas ahora”.

1.2. Objetivos

A continuación se detallan los objetivos que guían el presente trabajo de tesis, los cuales fueron definidos en el protocolo de investigación y constituyen la hoja de ruta para el desarrollo del sistema propuesto.

1.2.1. Objetivo General

El objetivo general es desarrollar un sistema basado en Machine Learning que permita predecir la congestión de redes de computadoras a partir del análisis de datos de operación, con el fin de optimizar la gestión de recursos, mejorar el rendimiento y garantizar la calidad del servicio en diferentes entornos.

1.2.2. Objetivos Específicos

- Recopilar y organizar datos de operación de una red de computadoras, incluyendo parámetros como frecuencia de operación, ancho de banda, rendimiento y disponibili-

dad.

- Diseñar un procedimiento para almacenar, depurar y procesar los datos obtenidos de una manera estructurada.
- Implementar técnicas de Machine Learning adecuadas para analizar los patrones de tráfico y comportamiento de la red.
- Desarrollar un prototipo que realice predicciones de posibles escenarios de congestión de red.
- Validar el desempeño del sistema mediante métricas de evaluación.
- Identificar posibles aplicaciones reales del sistema propuesto en distintos contextos de uso.

1.3. Justificación

El crecimiento exponencial del tráfico en las redes de computadoras ha superado las estrategias tradicionales de gestión basadas en la monitorización reactiva. Hoy en día, la demanda de ancho de banda generada por servicios de videoconferencia, plataformas de streaming, aplicaciones en la nube y dispositivos del Internet de las Cosas somete a las infraestructuras a picos de utilización impredecibles. En este escenario, los administradores se ven forzados a intervenir únicamente después de que los niveles de congestión ya han degradado la calidad del servicio, lo que deriva en una experiencia deficiente para los usuarios y, en ámbitos críticos, en pérdidas económicas o riesgos de seguridad. Por ello, se vuelve indispensable desarrollar herramientas que permitan anticipar la saturación de los enlaces, migrando de una operación reactiva a una gestión predictiva que tome decisiones antes de que la congestión se materialice.

La aplicación de técnicas de Machine Learning en el ámbito de las redes abre una oportunidad real para este cambio de paradigma [2]. A diferencia de los métodos estadísticos convencionales, los algoritmos de aprendizaje automático tienen la capacidad de descubrir patrones complejos y no lineales a partir de grandes volúmenes de datos de operación, como series temporales de utilización, latencia o pérdida de paquetes. Modelos como las redes neuronales recurrentes, los bosques aleatorios o las arquitecturas de aprendizaje profundo han demostrado un desempeño notable en la predicción de tráfico en otros contextos, pero su aplicación sistemática para anticipar la congestión en enlaces individuales constituye un área de investigación con vacíos aún por cubrir, particularmente en lo referente a la comparación de múltiples familias de modelos en condiciones realistas de operación.

En el ámbito práctico, un sistema que prediga con antelación suficiente que un enlace alcanzará su capacidad límite puede transformar la administración de redes. Por ejemplo, un operador podría redirigir flujos de tráfico, activar mecanismos de balance de carga, reducir la prioridad de aplicaciones no críticas o incluso aprovisionar recursos adicionales de forma automática antes de que el usuario note degradación alguna. Esta capacidad de anticipación resulta crucial en entornos donde la continuidad del servicio es prioritaria, como hospitales que dependen de telemedicina, entidades financieras con transacciones en tiempo real o plantas

industriales con procesos automatizados. De esta manera, la presente investigación no solo busca generar conocimiento teórico, sino también ofrecer una herramienta con un impacto directo en la fiabilidad y eficiencia de las infraestructuras digitales.

Desde el punto de vista metodológico, la propuesta de construir un prototipo basado en datos de operación reales y de evaluarlo mediante métricas rigurosas —como el error cuadrático medio, el error absoluto medio y la comparación de tasas de predicción a distintos horizontes temporales— aporta un procedimiento replicable para la comunidad académica y profesional. La selección de tres paradigmas de modelado (series temporales estadísticas, aprendizaje automático clásico y aprendizaje profundo) permite además trazar un mapa claro de las fortalezas y limitaciones de cada enfoque, ofreciendo criterios objetivos para futuras implementaciones. En un campo en el que la mayoría de los estudios se concentran en la predicción general del volumen de tráfico, esta tesis se distingue por colocar el foco en la detección temprana de un evento específico y operacionalmente relevante: la congestión.

Finalmente, la investigación se justifica por su alineación con las tendencias actuales de la industria hacia las redes autónomas y la inteligencia artificial aplicada a las operaciones de TI (AIOps). Grandes empresas del sector tecnológico y organismos de estandarización están impulsando la incorporación de modelos predictivos en los sistemas de gestión de red, reconociendo que la simple supervisión ya no es suficiente para soportar las demandas de latencia y disponibilidad de las aplicaciones del futuro. En este sentido, el trabajo propuesto contribuye a cerrar la brecha entre las capacidades teóricas del Machine Learning y su aplicación práctica en un problema real de ingeniería de redes, generando evidencia empírica sobre su viabilidad, precisión y pertinencia en escenarios de congestión.

1.4. Alcances y Limitaciones

El presente trabajo de tesis se circunscribe al desarrollo de un prototipo funcional de predicción de congestión, implementado enteramente en código y orientado a validar la viabilidad sobre un conjunto de datos de operación de red. El alcance del proyecto se limita a la construcción, entrenamiento y evaluación de estos modelos mediante métricas cuantitativas, sin comprometerse con el desarrollo de una interfaz gráfica de usuario, una aplicación empaquetada o un sistema de producción completo. Por lo tanto, los resultados deben interpretarse como una prueba de concepto que demuestra la capacidad predictiva de los algoritmos seleccionados, no como una solución lista para ser desplegada en un entorno operacional real.

En términos de datos, el prototipo trabaja sobre un único dataset recolectado de forma pasiva en un escenario de red específico. Si bien esto permite controlar las condiciones del experimento y asegurar la reproducibilidad, también restringe la generalización de las conclusiones a otras topologías, escalas de red o patrones de tráfico. No se contempla, por el momento, la adquisición de múltiples fuentes de datos, la simulación de diversas arquitecturas de red ni la incorporación de tráfico sintético. Estas decisiones metodológicas, comunes en estudios de factibilidad tempranos, constituyen una limitación que deberá ser abordada en futuras iteraciones del sistema [3].

Desde el punto de vista computacional, se ha establecido un límite práctico en la complejidad de los algoritmos y en los recursos de hardware empleados. El prototipo se ejecuta en un entorno de estación de trabajo convencional, sin recurrir a infraestructura de cómputo

distribuido o aceleración especializada (GPU de alto rendimiento). En consecuencia, los modelos profundos se configuran con un número acotado de capas y neuronas, y no se explora el ajuste exhaustivo de hiperparámetros mediante búsqueda en malla de gran tamaño. Este enfoque permite obtener resultados en tiempos razonables, pero sacrifica potencialmente la obtención del modelo óptimo absoluto, lo cual es una limitación deliberada acorde con el carácter prototípico del desarrollo.

Otra restricción relevante es que el sistema no opera en tiempo real sobre una red viva, sino que entrena y evalúa sobre trazas históricas. La predicción se realiza fuera de línea, asumiendo que los datos han sido previamente recolectados y preprocesados. Por tanto, no se han implementado mecanismos de ingestión continua de datos, detección de cambio de concepto ni reentrenamiento automático del modelo, aspectos que resultarían necesarios para una eventual transición a un sistema de alerta temprana en producción. Esta limitación es congruente con la elección de priorizar la comparación de modelos bajo condiciones controladas [4].

Finalmente, la evaluación de la congestión se efectúa exclusivamente sobre el factor de utilización del enlace. Otras métricas que pueden incidir en la percepción de congestión, como la variación del retardo (jitter) o la tasa de pérdida de paquetes, no son modeladas de manera directa por el prototipo, aunque se mencionan en la fundamentación teórica. Esta delimitación conceptual simplifica el problema de predicción y permite concentrar los esfuerzos en la metodología propuesta, pero reconoce que la congestión es un fenómeno multifactorial que podría beneficiarse de un análisis más holístico en el futuro.

Capítulo 2

Marco Teórico

2.1. Fundamentos de redes de computadoras

2.1.1. Modelo OSI y TCP/IP

2.1.2. Concepto de congestión

La congestión de red ocurre cuando la cantidad de datos que intenta atravesar un nodo o enlace supera su capacidad de procesamiento y transmisión. Este fenómeno es común en redes de comunicación donde múltiples dispositivos compiten de manera simultánea por los mismos recursos de red, provocando una degradación progresiva en el rendimiento general del sistema.

Una forma sencilla de comprender este problema es imaginar el ancho de banda como una tubería por la que circula agua. Mientras el flujo se mantenga dentro de la capacidad de la tubería, los datos pueden transmitirse de manera eficiente. Sin embargo, cuando la cantidad de paquetes excede un límite crítico, los depósitos temporales de los routers, conocidos como *buffers*, comienzan a llenarse rápidamente. Como consecuencia, los paquetes deben permanecer más tiempo en espera antes de ser procesados y reenviados, lo que incrementa la latencia de la comunicación. Este retraso no crece de forma lineal, sino que puede aumentar de manera acelerada y desproporcionada conforme se incrementa el tráfico de red.

Desde una perspectiva operativa, uno de los principales síntomas de la congestión es la pérdida de paquetes. Cuando la memoria intermedia del router alcanza su capacidad máxima, el dispositivo se ve obligado a descartar los paquetes entrantes debido a la falta de espacio disponible. Esta situación provoca retransmisiones por parte de los protocolos de comunicación, especialmente en TCP, lo que incrementa aún más la carga de tráfico y agrava el estado de congestión de la red.

Además de la pérdida de paquetes, la congestión puede ocasionar otros efectos negativos, como aumento en el tiempo de respuesta, variaciones en el retardo, disminución del rendimiento efectivo y una experiencia deficiente para aplicaciones sensibles al tiempo, como videollamadas, transmisión multimedia o servicios en tiempo real.

En esta tesis, la congestión de red se evalúa mediante el factor de utilización, el cual representa qué tan cerca se encuentra un enlace de alcanzar su capacidad máxima de transmisión. Este parámetro permite analizar el comportamiento de la red bajo diferentes niveles de carga

y determinar el punto en el que el rendimiento comienza a degradarse significativamente, provocando inestabilidad en la comunicación y reducción en la calidad del servicio.

2.1.3. Métricas de rendimiento

2.2. Técnicas de Machine Learning aplicables

2.2.1. Aprendizaje supervisado: regresión vs clasificación

2.2.2. Modelos de series temporales (ARIMA)

2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)

2.2.4. Modelos de Deep Learning (LSTM, GRU)

2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)

Capítulo 3

Estado del Arte

- 3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos
- 3.2. Predicción de tráfico/congestión con Machine Learning clásico
- 3.3. Predicción con Deep Learning
- 3.4. Herramientas de monitoreo y datasets utilizados
- 3.5. Síntesis del estado del arte y brecha a cubrir

Capítulo 4

Metodología

- 4.1. Tipo de investigación
- 4.2. Definición operativa de congestión
- 4.3. Descripción de las métricas a utilizar
- 4.4. Fuente de datos
- 4.5. Preprocesamiento de datos
- 4.6. Modelos a implementar y justificación de su elección
- 4.7. Métricas de evaluación del modelo
- 4.8. Herramientas y entorno

Capítulo 5

Desarrollo e Implementación

- 5.1. Obtención y exploración del dataset
- 5.2. Preprocesamiento
- 5.3. Construcción del modelo ARIMA
- 5.4. Construcción del modelo Random Forest
- 5.5. Construcción del modelo LSTM

Capítulo 6

Resultados y Discusión

- 6.1. Resultados de ARIMA
- 6.2. Resultados de Random Forest
- 6.3. Resultados de LSTM
- 6.4. Comparativa de modelos
- 6.5. Discusión

Capítulo 7

Conclusiones

7.1. Cumplimiento de objetivos

7.2. Contribuciones

7.3. Limitaciones del estudio

Referencias bibliográficas

Bibliografía

- [1] Cisco Systems, “Cisco annual internet report (2018–2023) white paper,” Cisco, Tech. Rep., 2020, consultado el 25 de mayo de 2026. [Online]. Available: <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>
- [2] R. Boutaba, M. A. Salahuddin, N. Limam, S. Ayoubi, N. Shahriar, F. Estrada-Solano, and O. M. Caicedo, “A comprehensive survey on machine learning for networking: evolution, applications and research opportunities,” *Journal of Internet Services and Applications*, vol. 9, no. 1, p. 16, 2018.
- [3] A. Boukerche, Y. Sun, and M. Z. A. Bhuiyan, “Performance evaluation of machine learning-based network traffic prediction approaches: A survey,” *IEEE Communications Surveys & Tutorials*, vol. 23, no. 1, pp. 405–428, 2021.
- [4] J. Zhang, Y. Liu, Z. Li, and Y. Lu, “Network traffic prediction using deep learning: An experimental study,” in *2020 IEEE 6th International Conference on Computer and Communications (ICCC)*, 2020, pp. 1320–1325.

Apéndice A

Código fuente de ejemplos críticos

Apéndice B

Capturas de pantalla adicionales