

Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias de la Computación



T E S I S

**“Predicción de congestión en redes de computadoras
utilizando técnicas de Machine Learning”**

Presenta:

Ricardo Valera Martinez

Para obtener el grado de:

Licenciatura en Ingeniería en Ciencias de la Computación

Director: **Mauro Alberto López Muñoz**

Codirector: **Guillermo Colorado Jiménez**

Puebla, Pue., Febrero 2026

Índice general

1. Introducción	6
1.1. Planteamiento del problema	6
1.2. Objetivos	7
1.2.1. Objetivo General	7
1.2.2. Objetivos Específicos	7
1.3. Justificación	7
1.4. Alcances y Limitaciones	7
2. Marco Teórico	8
2.1. Fundamentos de redes de computadoras	8
2.1.1. Modelo OSI y TCP/IP	8
2.1.2. Concepto de congestión	8
2.1.3. Métricas de rendimiento	9
2.2. Técnicas de Machine Learning aplicables	9
2.2.1. Aprendizaje supervisado: regresión vs clasificación	9
2.2.2. Modelos de series temporales (ARIMA)	9
2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)	9
2.2.4. Modelos de Deep Learning (LSTM, GRU)	9
2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)	9
3. Estado del Arte	10
3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos . .	10
3.2. Predicción de tráfico/congestión con Machine Learning clásico	10
3.3. Predicción con Deep Learning	10
3.4. Herramientas de monitoreo y datasets utilizados	10
3.5. Síntesis del estado del arte y brecha a cubrir	10
4. Metodología	11
4.1. Tipo de investigación	11
4.2. Definición operativa de congestión	11
4.3. Descripción de las métricas a utilizar	11
4.4. Fuente de datos	11
4.5. Preprocesamiento de datos	11
4.6. Modelos a implementar y justificación de su elección	11
4.7. Métricas de evaluación del modelo	11

4.8. Herramientas y entorno	11
5. Desarrollo e Implementación	12
5.1. Obtención y exploración del dataset	12
5.2. Preprocesamiento	12
5.3. Construcción del modelo ARIMA	12
5.4. Construcción del modelo Random Forest	12
5.5. Construcción del modelo LSTM	12
6. Resultados y Discusión	13
6.1. Resultados de ARIMA	13
6.2. Resultados de Random Forest	13
6.3. Resultados de LSTM	13
6.4. Comparativa de modelos	13
6.5. Discusión	13
7. Conclusiones	14
7.1. Cumplimiento de objetivos	14
7.2. Contribuciones	14
7.3. Limitaciones del estudio	14
Referencias bibliográficas	15
A. Código fuente completo	17
B. Capturas de pantalla adicionales	18

Índice de figuras

Índice de cuadros

DEDICATORIA

*A mi padre, **Ricardo Valera Hernandez**, por ser el pilar constante en cada etapa de mi formación, por su paciencia, su apoyo incondicional y por nunca dejar de creer en mí incluso cuando yo dudaba, por su ejemplo de responsabilidad y esfuerzo, por enseñarme que el trabajo honesto y la perseverancia son el camino para alcanzar cualquier meta.*

*A mi madre, **Maria Margarita Irma Martinez Perez**, por ser la guía y el apoyo incondicional que hizo posible este trayecto. Gracias por su confianza infinita, por sus palabras que siempre supieron darme fuerza y por estar presente en cada paso de mi formación profesional. Este trabajo es testimonio de su esfuerzo y dedicación constante en mi vida*

*A mi novia, **Vanessa F. Linarte Castañeda**, por su amor, su comprensión y su compañía en los momentos de cansancio y dificultad, por motivarme a seguir adelante cuando parecía imposible y por ser parte fundamental de este logro.*

*A mi hermano menor, **Emilio Valera Martinez**, por su complicidad y apoyo en los momentos de distracción y de enfoque. Gracias por estar ahí, por los consejos y por ser un compañero constante en este camino.*

*Al **Sr. Hector H. Linarte** y la **Sra. Cristina E. Castañeda**, por recibirme en su familia como a un hijo más, por sus palabras de aliento y por el apoyo incondicional brindado durante este proceso. Su confianza y cariño fueron fundamentales para mantener el ánimo en la recta final.*

*A mi director de tesis, el **Mtro. Mauro Alberto López Muñoz**, y a mi codirector, el **Mtro. Guillermo Colorado Jiménez**, por su invaluable guía, su paciencia y por compartir su conocimiento para llevar este proyecto a buen puerto.*

Capítulo 1

Introducción

“El futuro de las redes de computadoras no solo depende de transmitir datos más rápido, sino de hacerlo de manera inteligente.”

La evolución en las redes de computadoras ha permitido el desarrollo de una gran cantidad de servicios y aplicaciones que forman parte de la vida cotidiana, desde la navegación web y las plataformas de comunicación, hasta los sistemas distribuidos, la computación en la nube y el intercambio masivo de información en tiempo real. Debido a este crecimiento constante en la cantidad de dispositivos conectados y el volumen de tráfico generado, las redes modernas enfrentan cada vez mayores desafíos relacionados con el rendimiento, la disponibilidad y la calidad del servicio.

1.1. Planteamiento del problema

Vivimos en una era digital en la que la conectividad se ha convertido en un servicio esencial, tan fundamental como la electricidad o el agua corriente. Desde las videollamadas que nos acercan a nuestros familiares y colegas, hasta las plataformas de streaming que nos ofrecen entretenimiento bajo demanda, pasando por la explosión del internet de las cosas (IoT) que llena nuestros hogares y ciudades de sensores inteligentes, gran parte de nuestra vida cotidiana depende de un flujo constante e ininterrumpido de datos. Según el informe *Cisco Annual Internet Report (2018–2023)*, el número de usuarios de Internet a nivel mundial pasó de 3,900 millones en 2018 a 5,300 millones en 2023, mientras que los dispositivos conectados a redes IP aumentaron de 18,400 millones a 29,300 millones en el mismo período [1].

Las redes de computadoras son el tejido que sostiene cambios inminentes en la industria. Sin embargo no son un recurso infinito, cada enrutador, cada conmutador y cada enlace de fibra óptica tiene una capacidad limitada. Cuando la demanda de transmisión de datos supera esa capacidad se produce un fenómeno conocido como congestión de red, en términos sencillos (más adelante se abordará una definición apropiada para este trabajo) la congestión es el equivalente digital a un embotellamiento digital en una autopista, demasiados coches (paquetes de datos) intentando circular al mismo tiempo por un carril con aforo máximo. Las

consecuencias se vuelven inmediatas y totalmente perceptibles para el usuario final; videollamadas que se congelan, páginas web que cargan con lentitud, archivos que no terminan de descargarse o en el peor de los casos, se pierde totalmente la conexión. En entornos críticos como hospitales, sistemas de redes financieras o redes industriales, estos fallos se traducen en pérdidas económicas millonarias o incluso riesgos para la seguridad de las personas.

Tradicionalmente, la gestión de redes ha tenido un enfoque reactivo, los administradores de redes monitorizan equipos y, cuando detectan que un enlace está saturado toman medidas para correctivas como redirigir el tráfico, limitar ciertas aplicaciones o aumentar la capacidad de enlace. Este modo de actuar, aunque ha resultado funcional durante décadas, presenta una limitación fundamental: actúa después de que el problema ya ha comenzado a degradar la calidad del servicio. Pensemos en un coche autónomo que necesita tomar decisiones en milisegundos en tiempo real o en un cirujano operando a distancia mediante un robot, reaccionar después ya no es una opción, se necesita anticipación.

En este contexto, surge una pregunta clave: ¿es posible predecir que un enlace se va a congestionar con suficiente antelación para que un sistema automático o un administrador pueda evitarlo? La respuesta a esta pregunta pasa por abandonar la simple monitorización a adentrarse en el terreno del análisis predictivo. Aquí es donde entran en juego las técnicas de Machine Learning (ML), una rama de la inteligencia artificial que permite a las máquinas aprender patrones a partir de datos históricos y realizar predicciones sin ser programadas explícitamente para cada escenario.

El presente trabajo de tesis se sitúa justo en esta intersección entre las redes de computadoras y la inteligencia artificial. El objetivo central es desarrollar un sistema basado en técnicas de Machine Learning que sea capaz de predecir la congestión en un enlace de red a partir del análisis de métricas de tráfico obtenidas de forma pasiva. En lugar de limitarnos a reaccionar cuando la utilización ya está en niveles críticos, busco construir un modelo que pueda alertar con varios minutos de antelación: "Atención este enlace alcanzará el 85 % de su capacidad, toma medidas ahora "

1.2. Objetivos

Los objetivos aun no los escribo XD pero son los que aparecen en el documento de protocolo

1.2.1. Objetivo General

1.2.2. Objetivos Específicos

1.3. Justificación

1.4. Alcances y Limitaciones

Capítulo 2

Marco Teórico

2.1. Fundamentos de redes de computadoras

2.1.1. Modelo OSI y TCP/IP

2.1.2. Concepto de congestión

La congestión de red ocurre cuando la cantidad de datos que intenta atravesar un nodo o enlace supera su capacidad de procesamiento y transmisión. Este fenómeno es común en redes de comunicación donde múltiples dispositivos compiten de manera simultánea por los mismos recursos de red, provocando una degradación progresiva en el rendimiento general del sistema.

Una forma sencilla de comprender este problema es imaginar el ancho de banda como una tubería por la que circula agua. Mientras el flujo se mantenga dentro de la capacidad de la tubería, los datos pueden transmitirse de manera eficiente. Sin embargo, cuando la cantidad de paquetes excede un límite crítico, los depósitos temporales de los routers, conocidos como **buffers**, comienzan a llenarse rápidamente. Como consecuencia, los paquetes deben permanecer más tiempo en espera antes de ser procesados y reenviados, lo que incrementa la latencia de la comunicación. Este retraso no crece de forma lineal, sino que puede aumentar de manera acelerada y desproporcionada conforme se incrementa el tráfico de red.

Desde una perspectiva operativa, uno de los principales síntomas de la congestión es la pérdida de paquetes. Cuando la memoria intermedia del router alcanza su capacidad máxima, el dispositivo se ve obligado a descartar los paquetes entrantes debido a la falta de espacio disponible. Esta situación provoca retransmisiones por parte de los protocolos de comunicación, especialmente en TCP, lo que incrementa aún más la carga de tráfico y agrava el estado de congestión de la red.

Además de la pérdida de paquetes, la congestión puede ocasionar otros efectos negativos, como aumento en el tiempo de respuesta, variaciones en el retardo, disminución del rendimiento efectivo y una experiencia deficiente para aplicaciones sensibles al tiempo, como videollamadas, transmisión multimedia o servicios en tiempo real.

En esta tesis, la congestión de red se evalúa mediante el factor de utilización, el cual representa qué tan cerca se encuentra un enlace de alcanzar su capacidad máxima de transmisión. Este parámetro permite analizar el comportamiento de la red bajo diferentes niveles de carga

y determinar el punto en el que el rendimiento comienza a degradarse significativamente, provocando inestabilidad en la comunicación y reducción en la calidad del servicio.

2.1.3. Métricas de rendimiento

2.2. Técnicas de Machine Learning aplicables

2.2.1. Aprendizaje supervisado: regresión vs clasificación

2.2.2. Modelos de series temporales (ARIMA)

2.2.3. Modelos de aprendizaje automático (Random Forest, SVR)

2.2.4. Modelos de Deep Learning (LSTM, GRU)

2.2.5. Métricas de evaluación (RMSE, MAE, MAPE)

Capítulo 3

Estado del Arte

- 3.1. Revisión de trabajos sobre predicción de tráfico con métodos estadísticos
- 3.2. Predicción de tráfico/congestión con Machine Learning clásico
- 3.3. Predicción con Deep Learning
- 3.4. Herramientas de monitoreo y datasets utilizados
- 3.5. Síntesis del estado del arte y brecha a cubrir

Capítulo 4

Metodología

- 4.1. Tipo de investigación
- 4.2. Definición operativa de congestión
- 4.3. Descripción de las métricas a utilizar
- 4.4. Fuente de datos
- 4.5. Preprocesamiento de datos
- 4.6. Modelos a implementar y justificación de su elección
- 4.7. Métricas de evaluación del modelo
- 4.8. Herramientas y entorno

Capítulo 5

Desarrollo e Implementación

- 5.1. Obtención y exploración del dataset
- 5.2. Preprocesamiento
- 5.3. Construcción del modelo ARIMA
- 5.4. Construcción del modelo Random Forest
- 5.5. Construcción del modelo LSTM

Capítulo 6

Resultados y Discusión

- 6.1. Resultados de ARIMA
- 6.2. Resultados de Random Forest
- 6.3. Resultados de LSTM
- 6.4. Comparativa de modelos
- 6.5. Discusión

Capítulo 7

Conclusiones

7.1. Cumplimiento de objetivos

7.2. Contribuciones

7.3. Limitaciones del estudio

Referencias bibliográficas

Bibliografía

- [1] Cisco Systems, “Cisco annual internet report (2018–2023) white paper,” Cisco, Tech. Rep., 2020, consultado el 25 de mayo de 2026. [Online]. Available: <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>

Apéndice A

Código fuente completo

Apéndice B

Capturas de pantalla adicionales