

PROYECTO DE TRABAJO DE TESIS

FECHA: 15/10/2025

(La fecha deberá ser no mayor a 2 días antes del envío vía digital o la fecha deberá ser del día de la entrega)

I Datos Generales.

1.1 Datos del Estudiante.

(Datos completos del estudiante)

Nombre: Ricardo Valera Martinez

Matrícula: 202060187

Carrera: Ingeniería en Ciencias de la Computación

Dirección: Calle de las Flores, #1219 Col. La providencia (Gregorio Ramos)

Teléfono Particular: 2213697522

Correo institucional: ricardo.valeram@alumno.com

Correo personal: ricardovaleramartinez@hotmail.com

1.2 Título del Proyecto de Tesis.

Predicción de congestión en redes de computadoras utilizando técnicas de Machine Learning

1.3 Institución de Realización.

(Nombre de la institución en donde se desarrollará el Proyecto, especificando hasta el nivel de Departamento de adscripción. Si el proyecto se va a desarrollar en dos o más instituciones, favor de anotar la información correspondiente).

Nombre: Benemérita Universidad Autónoma de Puebla

Departamento: Facultad de Ciencias de la Computación.

Dirección: Av. San Claudio s/n, Cd Universitaria, La Hacienda, 72592 Heroica Puebla de Zaragoza, Pue.

Teléfono: +522222295500

1.4 Beca de Tesis.

(Si se ha Tramitado alguna Beca proporcione la información correspondiente)

Institución que otorga la Beca:

Tipo de Beca:

Vigencia:

1.5 Proyecto de Origen.

(Si su proyecto forma parte de algún Proyecto de Investigación Proporcione la siguiente información.)

Institución:

Nombre del Proyecto:

Responsable del Proyecto:

Fuente de Financiamiento:

1.6 Datos del Director.

*(Datos Completos del Director,
Director debe ser docente adscrito a la Facultad de Ciencias de la Computación)*

Nombre: Mauro Alberto López Muñoz

Dirección: Calle Hermanos Flores Magón 14 Insurgentes Oriente 72540 Heroica Puebla de Zaragoza, Pue.

Teléfono Particular: 2221564958

Institución: Benemérita Universidad Autónoma de Puebla

Unidad Académica de Adscripción: Facultad de Ciencias de la Computación.

Teléfono de Unidad Académica: +522222295500

Grado Académico: Maestría

1.7 Datos del Codirector.

Nombre: Guillermo Colorado Jiménez

Dirección: Primera de Ocotan 8B, Santa María Xonacatepec

Teléfono Particular: 2211508012

Unidad Académica de Adscripción: Facultad de Ciencias de la Computación

Teléfono de Unidad Académica: +522222295500

Grado Académico: Maestría

Justificación:

La participación del Mtro. Guillermo Colorado en el desarrollo de este trabajo de tesis se fundamenta en su formación académica como maestro en ingeniería y en su actual labor docente en el área de redes de computadoras. Su incorporación responde a la necesidad de integrar perspectivas pedagógicas y técnicas que fortalezcan el enfoque aplicado del proyecto.

El Mtro. Colorado se encuentra en proceso de consolidación en el campo de redes, lo que le permite aportar una visión renovada y crítica sobre los desafíos contemporáneos en la gestión del tráfico de datos. Su experiencia docente facilita la articulación de conceptos complejos de manera accesible, lo cual resulta valioso

tanto para la validación didáctica de los modelos propuestos como para su eventual implementación en entornos educativos.

Asimismo, su participación contribuye al fortalecimiento del vínculo entre la investigación académica y la práctica profesional, promoviendo la formación de capacidades en el uso de técnicas de aprendizaje automático para la optimización de redes. Esta colaboración se alinea con los objetivos de formación integral y transferencia de conocimiento que orientan el presente trabajo.

II Descripción del Proyecto.

2.1 Resumen.

El crecimiento acelerado de las redes de computadoras y el incremento constante en la demanda de servicios digitales han generado un aumento en la probabilidad de congestión, lo cual repercute en la calidad del servicio, la latencia y la disponibilidad de recursos. Si bien existen mecanismos tradicionales en la gestión de tráfico, estos resultan limitados frente a la complejidad y variabilidad del tráfico actual. En este contexto el uso de técnicas de Machine Learning representa una alternativa prometedora para anticipar eventos de congestión y optimizar la administración de redes.

El presente trabajo tiene como objetivo desarrollar un sistema basado en Machine Learning que permita predecir la congestión en redes de computadoras mediante el análisis de datos de operación, tales como el ancho de banda, rendimiento y disponibilidad (entre otros). Para ello, se recopilarán datos de tráfico en condiciones controladas, se almacenarán en una base estructurada y se implementarán algoritmos de aprendizaje supervisado para identificar patrones asociados con estados de congestión.

Se espera que el sistema propuesto permita anticipar escenarios de saturación con un nivel adecuado de precisión y de confiabilidad, contribuyendo a la toma de decisiones en la gestión de redes. Entre sus posibles aplicaciones destacan los proveedores de servicios de internet, centros de datos, redes empresariales y entornos inalámbricos, donde la predicción temprana de congestión puede mejorar significativamente la calidad del servicio.

2.2 Antecedentes del Proyecto.

La congestión en redes de computadoras ha sido un problema recurrente desde la expansión del internet y el aumento del tráfico de datos en diferentes entornos. Este fenómeno se produce cuando la demanda de recursos supera la capacidad de transmisión, lo que genera retrasos, pérdida de paquetes y degradación en la calidad del servicio. A lo largo de los años, se han desarrollado múltiples estrategias para mitigar este problema, desde la gestión del tráfico en los routers hasta el uso de algoritmos de control de flujo. Sin embargo, la naturaleza

cambiante y dinámica de las redes modernas hace que las soluciones tradicionales resulten ineficientes en muchos escenarios.

Con la llegada de las nuevas tecnologías como el internet de las cosas, los servicios en la nube y las redes móviles de quinta generación, la cantidad de dispositivos conectados y el volumen de información transportada han crecido de manera exponencial. Esto ha incrementado la probabilidad de eventos de congestión, dificultando la administración eficiente de los recursos de la red. En este contexto, la capacidad de anticipar la congestión se ha convertido en un factor estratégico para mantener la estabilidad de los servicios y garantizar la satisfacción de los usuarios finales.

Los métodos convencionales para gestionar el tráfico de red se basan en modelos matemáticos y en la implementación de políticas estáticas, que en muchos casos no se adaptan a los cambios tan bruscos de la demanda. Estas aproximaciones funcionan de manera adecuada en redes pequeñas o en escenarios de un tráfico predecible, pero presentan limitaciones cuando se aplican a entornos complejos y heterogéneos. La evolución de los servicios digitales ha generado la necesidad de contar con herramientas más flexibles, capaces de aprender y adaptarse a condiciones variables de forma automática.

En este panorama, el uso de técnicas de Machine Learning ha surgido como una alternativa para abordar el problema de la congestión. Estas técnicas permiten analizar grandes volúmenes de datos de operación y detectar patrones que pueden ser asociados con situaciones de saturación. A diferencia de los métodos tradicionales, los algoritmos de aprendizaje automático pueden mejorar su desempeño conforme se les proporciona más información, lo que los convierte en una opción más atractiva para enfrentar la creciente complejidad de las redes modernas

El desarrollo de sistemas predictivos basados en Machine Learning abre la posibilidad de anticipar la congestión antes de que ocurra, ofreciendo a los administradores de red la oportunidad de tomar medidas preventivas. Esto no solo contribuye a optimizar la distribución de recursos, sino que también permite mejorar la experiencia del usuario y reducir las pérdidas económicas asociadas a interrupciones en el servicio. Así los antecedentes del problema muestran evolución desde los enfoques tradicionales de gestión hacia soluciones inteligentes, sentando las bases para investigaciones que, como la presente, buscan aplicar técnicas avanzadas de análisis y predicción en beneficio de la administración de redes de computadoras.

2.3 Objetivos Generales y Específicos del Proyecto.

- **General**
 - *Desarrollar un sistema basado en Machine Learning que permita predecir la congestión en redes de computadoras a partir del análisis de datos de*

operación con el fin de optimizar la gestión de recursos, mejorar el rendimiento y garantizar la calidad del servicio en distintos entornos.

- *Específicos*
 - *Recopilar y organizar datos de operación de una red de computadoras, incluyendo parámetros como frecuencia de operación, ancho de banda, rendimiento y disponibilidad.*
 - *Diseñar un procedimiento para almacenar, depurar y procesar los datos obtenidos de una manera estructurada.*
 - *Implementar técnicas de Machine Learning adecuadas para analizar los patrones de tráfico y comportamiento de la red.*
 - *Desarrollar un prototipo que realice predicciones de posibles escenarios de congestión de red.*
 - *Validar el desempeño del sistema mediante métricas de evaluación*
 - *Identificar posibles aplicaciones reales del sistema propuesto en distintos contextos de uso.*

2.4 Metodología.

La presente investigación seguirá un enfoque aplicado, orientado al diseño y validación de un sistema predictivo de congestión en redes de computadoras.

1. Planteamiento del problema

La congestión en redes de comunicación constituye uno de los principales desafíos para garantizar un servicio eficiente y confiable, cuando la demanda de tráfico supera la capacidad de transmisión, se generan retrasos, pérdida de paquetes y degradación de la calidad en las aplicaciones. En este contexto, resulta fundamental contar con mecanismos capaces de anticipar la congestión antes de que esta ocurra, con el fin de implementar acciones preventivas y mantener la estabilidad de la red

2. Hipótesis

Se plantea que, mediante el análisis de métricas clave del tráfico de red y la implementación de algoritmos de aprendizaje supervisado, es posible anticipar escenarios de congestión con un nivel de precisión adecuado. De esta manera, un software especializado puede ofrecer recomendaciones oportunas que permitan a los administradores de red prevenir fallos o implementar estrategias de balanceo de carga

3. Diseño y desarrollo del sistema

La propuesta considera el desarrollo de un software compuesto por tres etapas principales:

- *Recolección de datos: se recopilarán métricas como ancho de banda, utilizando latencia, jitter y pérdida de paquetes (entre otros).*
- *Análisis predictivo: El módulo de análisis aplicará técnicas estadísticas, modelos de aprendizaje supervisado y modelos de predicción para identificar patrones de comportamiento asociados a posibles episodios de congestión.*

- *Generación de recomendaciones: El sistema generara alertas y sugerencias de acción preventivas, como redistribución del tráfico o ajuste en la priorización de servicios.*

La fase de desarrollo contempla la programación del software empleando un lenguaje de propósito general (por ejemplo, Python) y librerías específicas para el manejo de tráfico y visualización de datos. Se diseñará una interfaz que muestre en tiempo real los indicadores de la red y las predicciones generadas, garantizando que el sistema sea comprensible y utilizable por administradores con diferentes niveles de experiencia. Además, se incorporarán funciones de registro histórico para permitir comparaciones con diferentes niveles de experiencia.

4. Técnicas y métodos

Para el desarrollo del sistema de predicción de congestión en redes se emplearán técnicas y métodos en tres dimensiones principales: recopilación de datos, análisis mediante Machine Learning y diseño de software.

- *Técnicas de recolección de datos: Se implementará un sistema de captura de tráfico en un entorno controlado, utilizando herramientas de monitoreo de red como Wireshark, tcdump o librerías de programación como scrapy. Estas técnicas permitirán obtener métricas relevantes como ancho de banda, utilizando latencia, jitter, pérdida de paquetes y rendimiento general de la red. Los datos recolectados se almacenarán en una base de datos estructuradas, de manera que puedan ser consultados y reutilizados en diferentes etapas del proyecto.*
- *Métodos de análisis y predicción: Para identificar patrones asociados a la congestión se aplicarán algoritmos de Machine Learning supervisado, tales como la regresión logística, máquinas de soporte vectorial (SVM) o árboles de decisión. En caso de disponer de suficientes datos, se evaluará también el uso de redes neuronales simples. La metodología del análisis consistirá en dividir el conjunto de datos en subconjuntos de entrenamiento y prueba, aplicar técnicas de normalización y validación cruzada, y calcular métricas de desempeño como exactitud, sensibilidad y precisión.*
- *Técnicas de desarrollo de software: El sistema será implementado siguiendo una metodología de desarrollo incremental, que permita construir módulos funcionales de manera progresiva. Se empleará un lenguaje de programación de alto nivel (Python) por su amplia disponibilidad de librerías para el análisis de datos (pandas, sickit-learn, numpy) y visualización (matplotlib, seaborn). Asimismo, se integrará una interfaz gráfica que facilite la interacción con los resultados y recomendaciones del sistema, utilizando frameworks ligeros como Tkinter o Dash.*

5. Validación y pruebas del sistema

El software será sometido a un proceso de validación en un entorno controlado, donde se simularán distintos niveles de carga de red. Se evaluará la precisión de las predicciones comparándolas con los eventos reales de congestión, así como la eficacia de las recomendaciones emitidas. Se aplicarán métricas de desempeño como exactitud, tiempo de respuesta y reducción del impacto de la congestión. Los resultados obtenidos permitirán confirmar o rechazar la hipótesis y servirán de base para futuros perfeccionamientos del sistema.

2.5 Cronograma de Actividades.

No.	Actividades	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8	Mes 9	Mes 10	Mes 11
1	Revisión bibliográfica y definición del marco teórico.	x	x									
2	Planteamiento del problema e hipótesis	x	x									
3	Diseño conceptual del sistema.		x	x	x							
4	Preparación del entorno de experimentación.		x	x	x							
5	Procesamiento y organización de los datos.			x	x	x	x	x				
6	Desarrollo de un módulo de análisis predictivo.				x	x	x	x				
7	Desarrollo de software e integración.					x	x	x	x			
8	Validación del sistema.							x	x	x		
9	Documentación técnica y redacción de resultados.								x	x	x	
10	Conclusiones y aplicaciones reales.	x	x	x	x	x	x	x	x	x	x	x
11	Revisión y preparación de la defensa	x	x	x	x	x	x	x	x	x	x	x

2.6 Infraestructura.

(Descripción en forma genérica de los recursos disponibles para desarrollar el proyecto. Lo cual puede incluir: Equipo de cómputo, software, maquinaria, instrumentos, etc.)

Laptop: Fundamental para programar, analizar datos y probar la interfaz de usuario. Se utilizará para escribir el código necesario para el diseño y funcionamiento de la interfaz.

Entornos de desarrollo: Visual Studio Code.

Lenguaje de programación: Lenguaje de alto nivel (Python).

Librerías: Para Machine Learning y análisis de datos entre las que se encuentran, numpy; pandas; matplotlib; scikit-learn.

Herramientas de captura y análisis de tráfico: Wireshark, tcpdump.

Infraestructuras de red: Red local (LAN) en caso de hacer simulaciones.

2.7 Estado del Campo o del Arte.

La investigación sobre la predicción del tráfico y la congestión en redes ha evolucionado desde métodos estadísticos clásicos hasta enfoques basados en aprendizaje automático y aprendizaje profundo. En el área de redes celulares y de datos se ha identificado que los modelos de series temporales tradicionales ofrecen un punto de partida, pero presentan limitación para capturar patrones espaciales y temporales complejos presentes en redes modernas. Por ello, estudios de revisión han resaltado la transición hacia modelos data-driven que integran representaciones temporales y espaciales para mejorar la exactitud de las predicciones [1].

Los enfoques de aprendizaje profundo han ganado relevancia por su capacidad de modelar dependencias temporales largas y relaciones no lineales en el flujo de tráfico. Arquitecturas híbridas que combinan componentes recurrentes (LSTM/GRU), convolucionales (CNN) y mecanismos de atención han mostrado mejoras en la predicción a corto y mediano plazo, especialmente cuando se dispone de grandes cantidades de datos y representación adecuada del grafo de la red. Sin embargo, estas soluciones suelen requerir cuidado en el diseño de features y en la escalabilidad para entornos en tiempo real [2].

Paralelamente han surgido propuestas que exploran la preformación (pre-training) y el fine-tuning de modelos generales sobre registros de tráfico (por ejemplo, NetFlow) para luego adaptar dichos modelos a tareas concretas como la detección de anomalías o predicción de congestión. Esta línea es prometedora porque puede reducir la necesidad de grandes volúmenes de etiquetas específicas y favorecer la transferencia entre dominios o topologías distintas, algo especialmente valioso en redes heterogéneas y entornos con pocos datos etiquetados [3].

En cuanto a la dirección y predicción de eventos asociados a pérdida de paquetes y congestión, trabajos recientes han demostrado que clasificadores supervisados (Random Forest, Gradient Boosting, SVM) y modelos basados en aprendizaje profundo pueden distinguir entre pérdida por congestión y pérdida por otros motivos, lo cual es crucial para diseñar propuestas automatizadas. Dichos estudios también subrayan la importancia de generar datasets simulados o etiquetados cuidadosamente (por ejemplo, mediante ns-3 o entornos controlados) para evaluar los modelos bajo condiciones conocidas [4].

En el contexto de redes de nueva generación (5G/B5G) y entornos IoT, la predicción de tráfico enfrenta retos adicionales: mayor heterogeneidad de servicios, requisitos de latencia estricta y variaciones rápidas en patrones de uso. Investigaciones recientes proponen modelos multitarea o modelos que fusionan múltiples fuentes de datos (telemetría de red, métricas de usuario, topología) para mejorar la robustez de la predicción y permitir decisiones de orquestación en tiempo real. Estas obras enfatizan además la necesidad de soluciones que equilibren precisión y coste computacional [5].

A pesar de los avances, persisten brechas relevantes que justifican trabajos como el que se propone. Entre las limitaciones destacadas están: la dificultad para generalizar modelos entre distintas topologías de red, la escasez de conjuntos de datos públicos con etiquetas de congestión realistas, y la necesidad de integrar la predicción con mecanismos prácticos de recomendación y mitigación en tiempo razonable. La tesis se enfocará en el desarrollo de un sistema de predicción de congestión en redes que pueda ser replicable en distintos entornos, incorporando módulos capaces de generar recomendaciones prácticas para optimizar la gestión del tráfico. El objetivo es no solo anticipar escenarios de saturación, sino también evaluar el impacto de dichas predicciones en la operación real de la red. De esta manera, el trabajo se plantea como una contribución integral que combina la capacidad de análisis preventivo con la generación de acciones concretas, alineando directamente la hipótesis y los objetivos del proyecto.

2.8 Resultados Esperados.

Tesis

Sistema de predicción funcional

2.9 Impacto Socioeconómico.

La congestión en redes de comunicación afecta directamente a la productividad de empresas y organizaciones que dependen de servicios digitales en tiempo real. Retrasos en la transmisión de datos, pérdida de paquetes o interrupciones del servicio pueden generar pérdidas económicas significativas, especialmente en sectores financieros, industriales o de telecomunicaciones. Un sistema capaz de predecir la congestión permite optimizar las asignaciones de recursos, reducir interrupciones y mantener la continuidad de operaciones, contribuyendo así a la eficiencia operativa y la competitividad de organizaciones

En el ámbito educativo y de investigación, la disponibilidad de redes estables y eficientes facilita la interacción remota, la educación virtual y la colaboración en plataformas de enseñanza en línea, laboratorios virtuales y entornos de teleconferencia. Esto impacta positivamente en la calidad de aprendizaje y en la capacidad de las instituciones para favorecer servicios educativos de manera confiable, incrementando el acceso equitativo a recursos digitales.

A nivel social, la predicción de congestión en redes repercute en la conectividad de los ciudadanos, especialmente en áreas urbanas densamente pobladas o en zonas con una infraestructura más limitadas. Un sistema de monitoreo y predicción contribuye a garantizar la disponibilidad de servicios esenciales en cuanto a redes se refiere. La mejora en la calidad y estabilidad de la conectividad promueve la inclusión digital y disminuye la brecha entre usuarios con diferentes niveles de acceso a la tecnología

Desde el punto de vista económico y estratégico, la implementación de soluciones que anticipen la congestión puede traducirse en ahorros sustanciales para proveedores de servicios de internet y empresas que dependen de redes internas críticas. Además, la capacidad de generar recomendaciones preventivas basadas en análisis de datos permite diseñar políticas de gestión de tráfico más efectivas, reduciendo inversiones en infraestructura excesiva y optimizando la explotación de recursos existentes. Esto genera un efecto multiplicador, al mejorar tanto la eficiencia operativa como la experiencia de usuarios finales

2.10 Aportaciones.

El presente trabajo, propone como principal aportación el diseño y desarrollo de un sistema basado en técnicas de Machine Learning para la predicción de congestión de redes de computadora. A diferencia de enfoques tradicionales de monitoreo reactivo, este sistema busca anticipar eventos de congestión, permitiendo a los administradores de red tomar decisiones preventivas. Esta capacidad predictiva contribuye a la optimización de recursos, a la mejora en la calidad de servicio y a la reducción de interrupciones en entornos críticos.

Otra aportación relevante es la implementación de un proceso metodológico para la recopilación, almacenamiento y análisis de datos de red, integrando métricas clave como ancho de banda, latencia, rendimiento, disponibilidad, etc. Dicho proceso servirá como base para futuros proyectos de investigación, al establecer una referencia replicable en distintos escenarios, ya sea en entornos académicos, industriales o de proveedores de servicio de internet.

El proyecto también aporta un componente práctico mediante el desarrollo de software especializado que no solo analiza datos históricos, sino que además genera recomendaciones en tiempo real para mitigar el riesgo de congestión. Este enfoque trasciende la mera detección, ya que promueve la acción proactiva y la toma de decisiones informadas, lo que representa un avance en la gestión inteligente de redes.

2.11 Bibliografía.

(Enunciado de las referencias bibliográficas generales y específicas del área sobre la cual incide el proyecto.)

- [1] Jiang, W. (2022). Cellular traffic prediction with machine learning: A survey. *Expert Systems with Applications*, 201, 117163. <https://doi.org/10.1016/j.eswa.2022.117163>.
- [2] Zhou, J., Kim, W., Xu, Z., Rush, A. M., & Yu, M. (2024). NetFlowGen: Leveraging generative pre-training for network traffic dynamics. *arXiv preprint arXiv:2412.20635*. <https://doi.org/10.48550/arXiv.2412.20635>.
- [3] Uyan, U., Isyapar, M. T., & Uluyagmur, M. O. (2022). 5G long-term and large-scale mobile traffic forecasting. *arXiv preprint arXiv:2212.10869*.
- [4] Perifanis, V., Pavlidis, N., Yilmaz, S. F., Wilhelmi, F., Guerra, E., Miozzo, M., Efraimidis, P. S., Dini, P., & Koutsiamanis, R.-A. (2023). Towards energy-aware federated traffic prediction for cellular networks. *arXiv preprint arXiv:2309.10645*.
- [5] Pimpinella, A., Di Giusto, F., Redondi, A., Venturini, L., & Pavon, A. (2022). Forecasting busy-hour downlink traffic in cellular networks. *arXiv preprint arXiv:2207.01373*

III Firmas

(Firmas autógrafas con tinta azul que avalen la información requerida.)

Nombre y firma del Alumno: Ricardo Valera Martínez 
Nombre y firma del Director: Mauro Alberto López Muñoz 
Nombre y firma del Codirector: Guillermo Colorado Jiménez 

IV Dictamen de Comisión Revisora.

() APROBADO () A REVISIÓN () RECHAZADO

Nombre: _____ Firma: _____

Observaciones y Recomendaciones:

(En el caso de no tener observaciones, escribir "Sin observaciones")
